Rookiezpark — 고교야구 기록 · 지명 예측 플랫폼

머신러닝 기반 고교야구 선수의 프로 지명 가능성 예측 모델 개발

Team DRAFT LAB
류산성, 마태림, 표용희, 홍록기

DRAFT LAB

CONTENTS

01 서론

02 관련연구

03 설계

04 구현

05 결론

06 참고문헌

07 역할 분담과 일정 스케쥴

DRAFTLAB

1. 서론



DRAFTLAB

프로젝트 소개

- KBSA 고교야구 기록지 **7시즌(2020~2026)**을 수집·검증해 타석 단위로 정형화
- **리그 맞춤 세이버매트릭스**와 **LightGBM**으로 KBO 신인드래프트 지명 가능성 예측
- 결과를 웹 서비스 **rookiezpark.com**으로 공개하고 시즌 중 계속 갱신

입력

KBSA 기록지
(주자 상황 포함)

처리

3중 검수 · 스탯
엔진 · LightGBM

출력

웹 서비스
기록 · 랭킹 · 예측



DRAFTLAB

중간 발표 이후 — 모델에서 서비스로

	중간 발표 · DRAFT LAB 모델	최종 · Rookiezpark 서비스
데이터	2020~2025 6시즌	**2020~2026 7시즌**, 시즌 중 계속 갱신
검수	G·R·RBI 교차 검증	이닝 요약·타자·투수 공식 기록 **3중 대조** (차이 0까지)
지표	타율·OPS·FIP 등 일반 지표	이 리그 RE24로 추정한 **wOBA·wRC+·WPA**
모델 검증	교차 검증(OOF)	드래프트 전에 예측을 동결하고 **실제 결과로 채점**
결과물	Streamlit 시연 화면	웹 서비스 **rookiezpark.com** + 관리 도구

2. 관련 연구



DRAFTLAB

필요성 및 관련 연구

92억원

- KBO의 10개 구단은 평균 **92억원**의 계약금을 지불 (1차 지명 제도 폐지 후 4년 간의 평균 계약금 총액)

MLB

- MLB 구단들은 대학에 **Trackman**
- 장비를 설치하여 아마추어 선수 데이터를 수집 및 확보
- 이를 활용하여 **데이터 기반 스카우팅**

6건

- DBpia에서 **고교 야구 지명 예측**을 검색하면 6건의 논문이 전부
- 또한, 데이터를 **최대 20명**으로 밖에 설정하지 않았으며, **3~4개의 지표**만을 사용하여(ERA, WHIP, 피안타율 등) 분석
- 주제와 비슷한 관련 연구가 존재하지 않음

핵심 기능

01 주자 상황별 맥락 통계

득점권 타율, 만루 OPS 등 일반 집계 통계로 잡히지 않는 **클러치 능력**을 정량화

→ 기존 연구에서 단 한 번도 반영된 적 없는 **맥락 지표**

02 리그 맞춤 세이버매트릭스

MLB 상수를 빌리지 않고 이 리그의 RE24에서 **선형가중치를 직접 추정**해 wOBA·wRC+·FIP·WPA 계산

→ 고교야구 득점 환경에 맞춘 **리그 맞춤 지표**

03 지명 예측과 실전 검증

LightGBM으로 고3 선수의 **지명 확률**을 계산하고, 드래프트 전에 예측을 **동결**

→ 2027 드래프트 실제 결과로 채점해 **AUROC 0.867**

DRAFTLAB

차별성

구분	기존 연구	본 프로젝트
대상	투수, 타자 별도	투수 + 야수 (투타겸업 통합)
활용 지표 수	3~4개	30개+ (타자 25 · 투수 14 피처)
주자 상황	미포함	타석마다 1·2·3루 주자 추적
드래프트 예측	없음	핵심 목표
검증 방식	없음	사전 동결 → 실제 드래프트로 채점
샘플 수	6 ~ 20명	**11,258명** (7시즌 6,278경기)
데이터 출처	KBSA 일부	KBSA 기록지 전수 + 공식 기록 대조
결과 활용	논문	웹 서비스 rookiezpark.com

3. 설계



DRAFTLAB

상세 설계 — 시스템 아키텍처



경기 하나가 사이트에 뜨기까지 — 크롤 → 사람 보정 → 3중 검수 → 스탯 계산·JSON 굽기 → 자동 배포

검수에서 차이가 나면 보정 단계로 되돌아감 · 굽기(refresh_all.py 13단계) 약 15분 · 배포 16~20분

상세 설계 — 시스템 구성



사이트가 바뀌는 세 가지 길

① 코드 변경
web 브랜치 → PR → master 병합
반영 16~20분

② 기록 데이터
Colab 검수 → refresh_all.py → 자동 커밋
약 15분 + 배포 16~20분

③ 운영 데이터
관리 화면에서 입력 → Upstash
저장하는 즉시

상세 설계 — 데이터 검수 (3중 대조)

크롤 원본
기록지 xlsx
10경기씩 한 파일

▶

사람 보정
작업자가 엑셀로
원본을 직접 고침

▶

전처리
표기 정리 · 타석 번호
재정의 · 투수 채우기

▶

주자 추적
타석마다 1·2·3루
주자와 득점 재현

▶

3중 대조
공식 기록 3종과
하나하나 비교

3중 대조 — 코드로 다시 계산한 값 vs 협회 공식 기록

① 이닝별 아웃 · 점수
vs inning_summary (이닝 요약)

② 타자 성적
vs batter_box (타자 박스스코어)

③ 투수 성적
vs pitcher_box (투수 박스스코어)

차이 ≠ 0 → 사람 보정 단계로 되돌아가 기록지를 다시 고침

차이 = 0 → full_tracked → season_full (선수 번호 부여 · parquet 저장)

규칙으로 못 푸는 예외(부정위 타순 등)는 별도 표로 넣어 주자 추적이 읽음

0건
7시즌 전체 주자 추적 불일치

상세 설계 — 피처 설계 & 모델 설계

타자 25개

비율 11개
AVG · OBP · SLG · OPS · IsoP · IsoD · K% · BB% · BABIP · HR% · XBH%

기회량 1개
타석 수(PA)

이전 학년 누적 13개
고1 · 고2 성적을 더해 성장 흐름 반영

투수 14개

비율 10개
ERA · WHIP · FIP · BAA · K/9 · BB/9 · HR/9 · K% · BB% · K/BB

기회량 1개
이닝(IP)

상대 수준 2개
상대 타자 수준 · 전국대회 비율

K%oe 1개
상대 타자 · 구장을 보정한 삼진율

공통 — 같은 학년 안 **백분위**로 변환 · 표본 축소(PA 100 / IP 30) · 최소 50타석
드래프트 전 동결본은 투수 13개 — K%oe는 드래프트 뒤(10-04) 추가

LightGBM 모델 설계

01 **같은 학년 안 백분위**
해마다 리그 환경과 경기 수가 달라도 같은 눈금으로 비교

02 **얕은 트리 + 규제**
depth 3 · leaf 7 · 300그루 + L1·L2 규제로 과적합 억제

03 **연도별 leave-one-out 검증**
한 해를 통째로 빼고 학습 → 처음 보는 학년을 맞히는 실제 상황과 같게

04 **Platt 확률 보정**
OOF 예측으로 확률 눈금만 보정 — 순위와 AUROC는 그대로

상세 설계 — 평가 지표 & 사전 예측 동결

⚠ 왜 Accuracy를 사용하지 않는가?

2027 드래프트 대상 892명 중 지명 81명(9.1%) → 전원을 '미지명'으로 찍어도 Accuracy = 90.9% | 지명자를 얼마나 위로 올리는지로 평가

01

AUROC

지명자를 미지명자보다 위에 둘 확률. 0.5는 무작위, 1에 가까울수록 구분 능력 우수

02

Precision@K

상위 K명 중 실제 지명자 수. 스카우터가 후보 명단을 위에서부터 훑는 상황 그대로

03

확률 보정 (Platt)

'70%'라고 한 선수들이 실제로 70% 지명됐는지. OOF 예측으로 눈금만 맞춤

사전 예측 동결

드래프트 3일 전(2026-09-18) → 예측을 파일로 동결하고 이후 손대지 않음 | **2026-09-21 드래프트** → 실제 지명 결과로 채점
결과를 본 뒤 만든 모델 은 사후 분석(posthoc)으로 따로 보관해 사전 예측 성적과 섞지 않음

모델 검증 — 연도별 leave-one-out (2020~2025 고3)

고3 시즌 (드래프트)	대상	지명	AUROC	타자	투수	상위 10	상위 30	상위 50
2020 (2021)	804	80	0.847	0.774	0.915	9	19	29
2021 (2022)	818	90	0.863	0.868	0.854	9	20	29
2022 (2023)	816	91	0.905	0.899	0.908	10	26	35
2023 (2024)	794	80	0.887	0.892	0.882	10	20	32
2024 (2025)	848	93	0.938	0.928	0.948	10	28	43
2025 (2026)	919	93	0.875	0.874	0.876	8	23	35
합계 · 평균	**4999**	**527**	**0.886**	**0.872**	**0.895**	**9.3**	**22.7**	**33.8**

학습 **4,999명** 중 지명 **527명**(10.5%) · 드래프트 전 동결한 모델의 값 · 상위 K는 그 학년 안에서 센 실제 지명자 수

한 해를 통째로 빼고 검증

6개 학년 중 하나를 빼고 나머지로 학습 → 뺀 학년을 예측, 6번 반복

처음 보는 학년을 맞히는 구조

같은 학년 선수가 학습·검증에 섞이지 않아 실제 사용(내년 예측)과 같은 조건

해마다 고르게

AUROC 0.85~0.94 — 특정 연도에만 맞는 모델이 아님

확률 보정의 재료

이 OOF 예측으로 Platt 보정 계수를 맞춤

모델 검증 — 시간순 검증 (과거 시즌으로만 학습)

시험 학년 (드래프트)	학습 데이터	AUROC	90% 구간	상위 10	상위 30	상위 50	지표 하나 기준선
2022 (2023)	2020~2021	0.885	0.855 ~ 0.913	9	22	34	0.798
2023 (2024)	2020~2022	0.888	0.855 ~ 0.917	10	22	33	0.809
2024 (2025)	2020~2023	0.939	0.918 ~ 0.958	10	29	44	0.856
2025 (2026)	2020~2024	0.886	0.855 ~ 0.916	8	25	36	0.819
2026 (2027)	**2020~2025**	**0.888**	**0.860 ~ 0.915**	**8**	**18**	**30**	**0.798**

미래 데이터를 쓰지 않음

연도별 leave-one-out은 미래 학년도 학습에 섞임 → 그 해보다 앞선 시즌으로만 학습해 다시 잼

다섯 해 모두 0.88 이상

2년치(2020~2021)만으로도 0.885 · 해마다 지표 하나 기준선보다 0.07~0.09 높음

운이 아님

랜덤 시드 10개로 다시 돌린 AUROC 편차 최대 0.0016 · 동결본 2027도 0.867 (90% 0.84~0.90)

모델 검증 — 다른 모델과 비교 (왜 LightGBM인가)

	2020~2025 연도별 검증 (평균)				2027 드래프트 실전 (888명 · 지명 80)			
모델 (같은 피처 · 같은 검증)	**AUROC**	**상위 10**	**상위 30**	**상위 50**	**AUROC**	**상위 10**	**상위 30**	**상위 50**
지표 하나로 줄 세우기	0.808	6.3	15.2	24.0	0.798	8	17	23
로지스틱 회귀	0.897	8.8	23.3	34.0	0.901	7	18	28
랜덤포레스트	0.887	8.8	23.8	34.2	0.886	7	22	32
LightGBM (1학기 설정)	0.880	9.2	22.8	32.7	0.874	7	19	30
LightGBM (최종)	**0.893**	**9.5**	**23.8**	**35.0**	**0.888**	**8**	**18**	**30**

머신러닝 ≫ 지표 하나

OPS·FIP 하나로 세운 순위보다 AUROC **+0.085** (90% 구간 +0.070~+0.099) · 상위 50명 24 → 35명

모델끼리는 비슷

로지스틱 회귀와 차이 −0.010~+0.002로 구분 안 됨 (2027 실전은 로지스틱 0.901이 최고) → 성능은 **모델보다 피처 설계**에서 나옴

그래도 LightGBM

고1·2 기록이 없는 선수(결측)를 0으로 채우지 않고 그대로 다룸 · 1학기 설정보다 **+0.008~+0.018** · 상위 10명 적중 최고

DRAFTLAB

모델 검증 — 피처 설계 검증 (묶음을 빼 보면)

타자 모델

	검증 AUROC	2027 실전
전체 25개	**0.871** 기준	**0.853** 기준
– 이전 학년 13개	**0.851** -0.019	**0.831** -0.022
– 타석 수	**0.849** -0.022	**0.849** -0.004

투수 모델

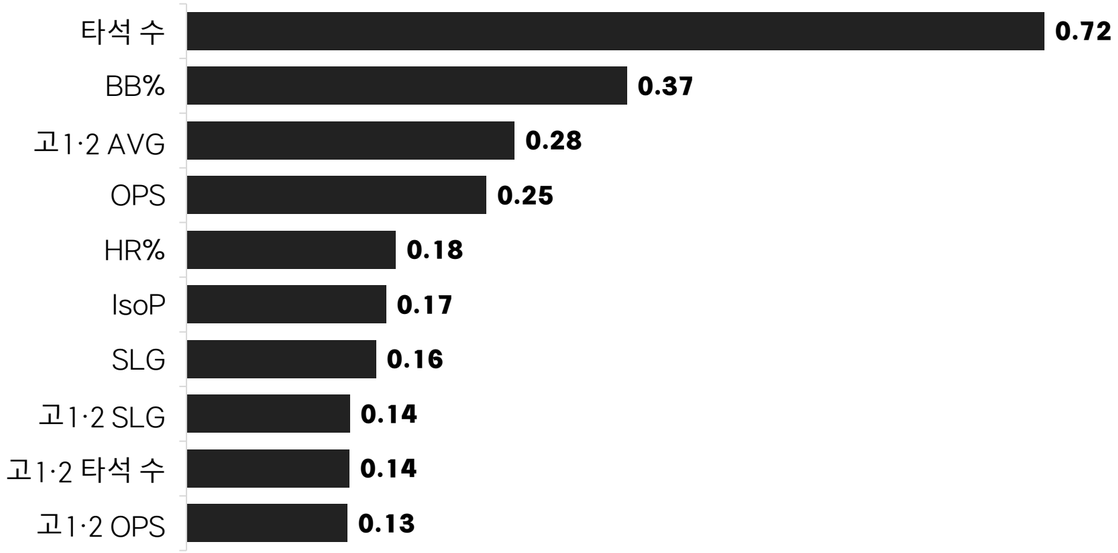
	검증 AUROC	2027 실전
전체 14개	**0.908** 기준	**0.899** 기준
– 상대 수준·전국대회 비율	**0.886** -0.022	**0.890** -0.009
– K%oe	**0.898** -0.009	**0.878** -0.020
– 이닝	**0.907** -0.001	**0.891** -0.007

타자는 '꾸준히 기용됐는가(타석 수)'와 '고1·2 성적'을, **투수**는 '누구를 상대로 던졌는가(상대 수준·전국대회)'를 빼면 크게 떨어짐 — 이닝 수는 기여 거의 없음

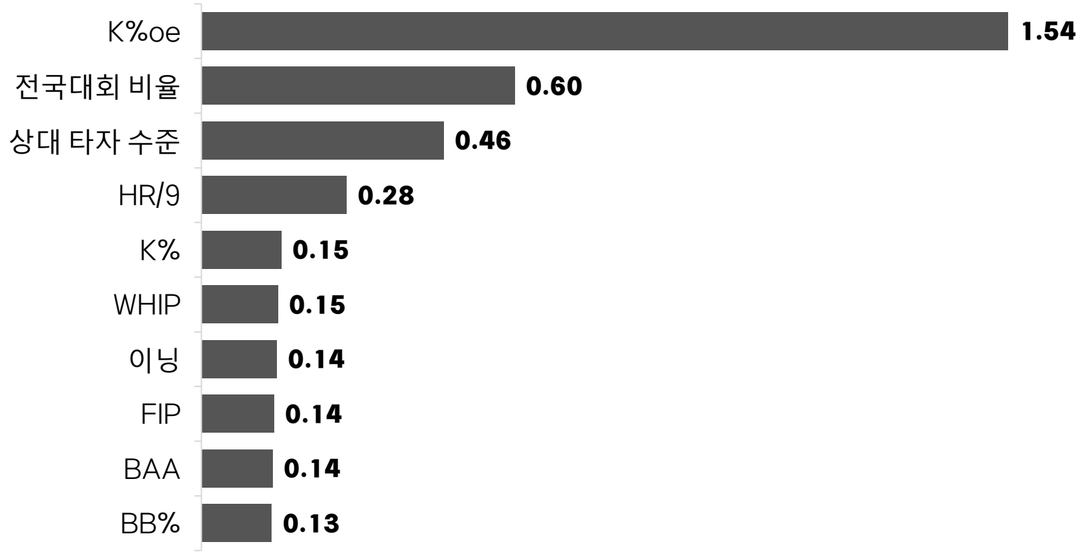
DRAFTLAB

모델 해석 — SHAP 피처 중요도 (무엇을 보고 판단하나)

타자 — 상위 10개 피처



투수 — 상위 10개 피처



타자: 기회와 출루가 먼저

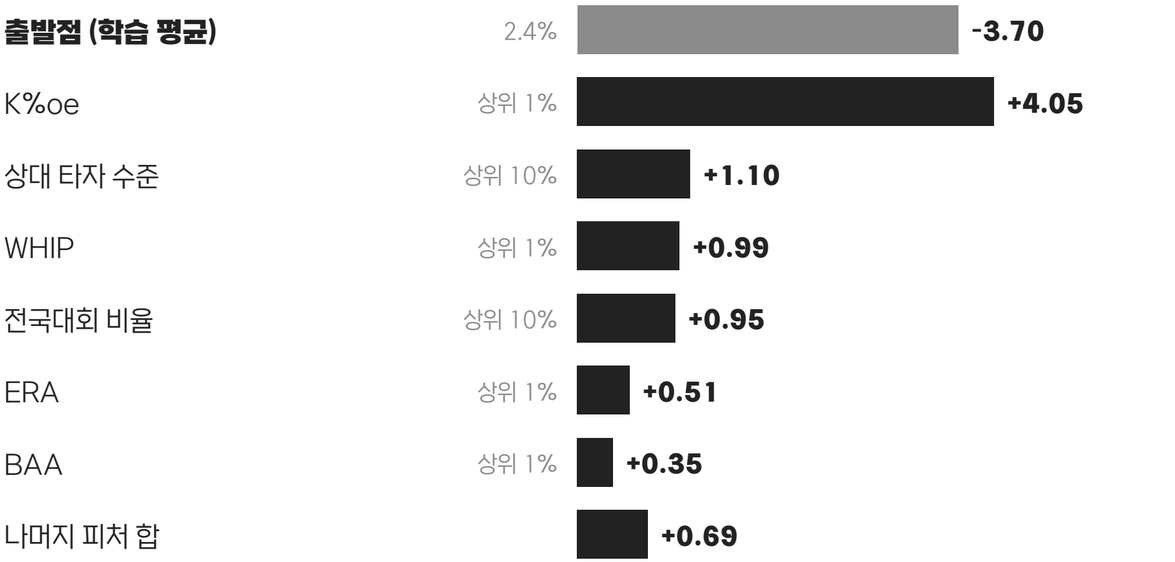
1위 **타석 수** — 주전으로 꾸준히 나온 선수 = 지도자가 이미 인정한 선수. 이어서 BB%·고1·2 타율·OPS·HR% 순

투수: 삼진 능력이 압도적

1위 **K%oe**(상대·구장 보정 삼진율)가 2위의 2.6배. 전국대회 비율·상대 수준이 뒤따르고 ERA·WHIP 같은 결과 지표는 하위

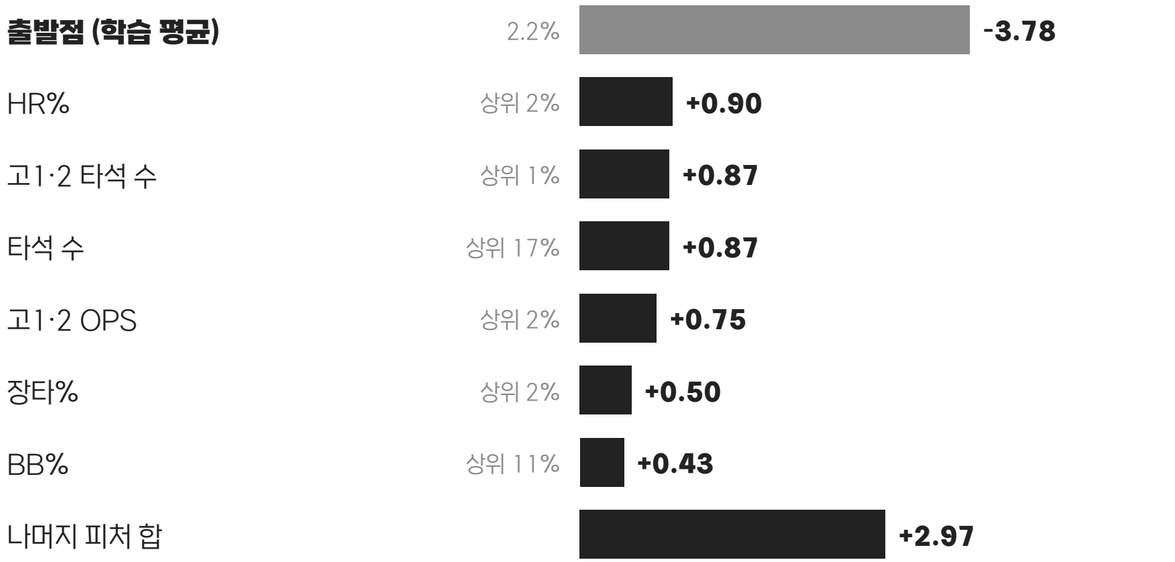
모델 해석 — 한 선수의 확률은 어떻게 만들어지나 (SHAP 분해)

2026 고3 투수 예측 1위



로그오즈 합 **+4.94** → 모델 확률 **99.3%** (보정 전)

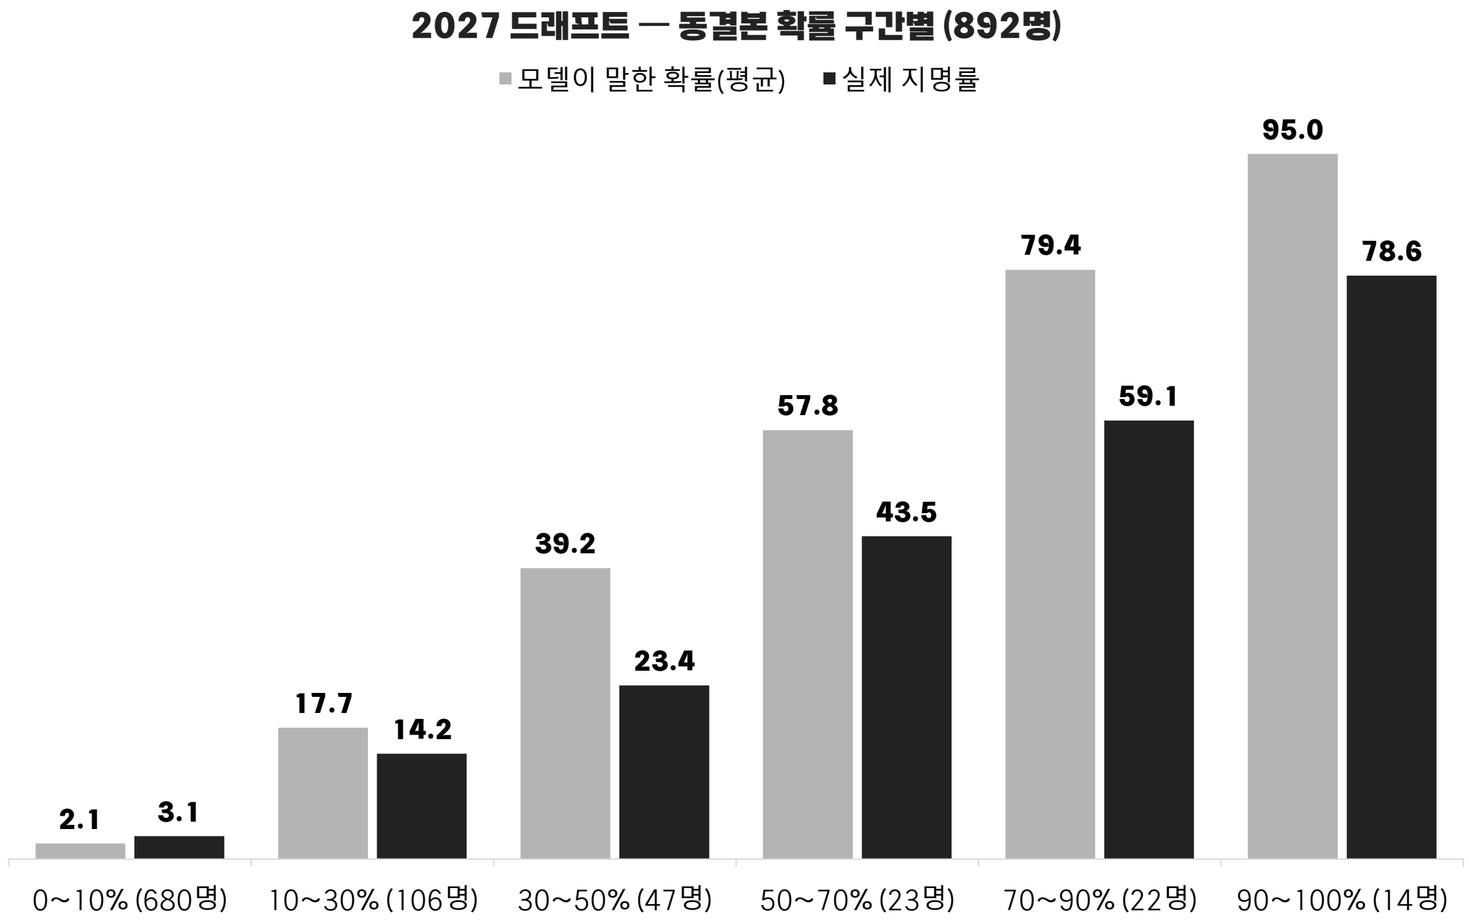
2026 고3 타자 예측 1위



로그오즈 합 **+3.50** → 모델 확률 **97.1%** (보정 전)

막대 = 그 피처가 확률(로그오즈)을 얼마나 밀어 올렸나 · 백분위는 같은 학년 안 순위(ERA·WHIP는 낮을수록 상위) · 사이트 확률은 Platt 보정·국가대표 가산 뒤 값

모델 검증 — 확률 보정 (모델이 말한 확률 vs 실제 지명률)



순위는 믿을 만

구간이 올라갈수록 실제 지명률도 차례로 올라감 — 줄 세우기(AUROC 0.867)는 정상

확률 상단은 과신

'90% 이상' 14명 중 실제 11명(78.6%) · '70~90%'는 59.1%

채점 뒤 Platt 보정 추가

동결본은 보정 전 값 · 로그오즈 기울기 타자 0.78 · 투수 0.81로 양끝을 안으로 당김 · 순위는 그대로

남은 과제

연도별 검증에서 보정 뒤에도 타자 '90% 이상'의 실제 지명률 81.8% · Brier 0.0582 → 0.0579

상세 설계 — 웹 서비스 (데이터 보호 & 권한)

데이터 접근 구조 — 통째로 가져갈 수 없게

web/data/.json **public 폴더 밖 — URL로 직접 받을 수 없음**

▼

서버의 readData() 파일은 서버에서만 읽음

▼

/api/* 라우트 입력 정규식 검증 + IP별 rate limit

▼

브라우저 화면에 필요한 조각만 받음

실명 고3 선수의 지명 확률은 서버 번들에만 — 브라우저로 보내지 않고 비밀번호·관리자만 열람

로그인 4등급

등급	볼 수 있는 것 · 할 수 있는 것
비로그인	공개 시즌(2023~2026)의 모든 기록
구글 로그인	+ 기록 오류 제보 · 커뮤니티 글쓰기 · 즐겨찾기
파트너	+ 비공개 선수 · 과거 시즌 · 구장 파크팩터
관리자	+ 관리 화면 · 드래프트 예측 · 데이터 반출

세션은 **서명 쿠키 하나** — 관리자 비밀번호를 바꾸면 발급된 세션이 자동으로 무효

DRAFTLAB

4. 구현



DRAFTLAB

개발 환경

언어 / 런타임

Python 3.12

Google Colab · 로컬 PC

ML 프레임워크

LightGBM 4.7

scikit-learn · statsmodels

웹 프레임워크

Next.js 16

React 19 · TypeScript · Tailwind 4

데이터 처리

pandas 3.0 · numpy

pyarrow(parquet) · openpyxl

배포 · CI

Vercel

GitHub Actions (lint → tsc → deploy)

저장소

Google Drive · Upstash

GitHub 비공개 저장소 2개

KBSA 기록지 ▶ 사람 보정 + 3중 검수 ▶ 스탯 엔진 ▶ JSON 굽기 ▶ rookiezpark.com

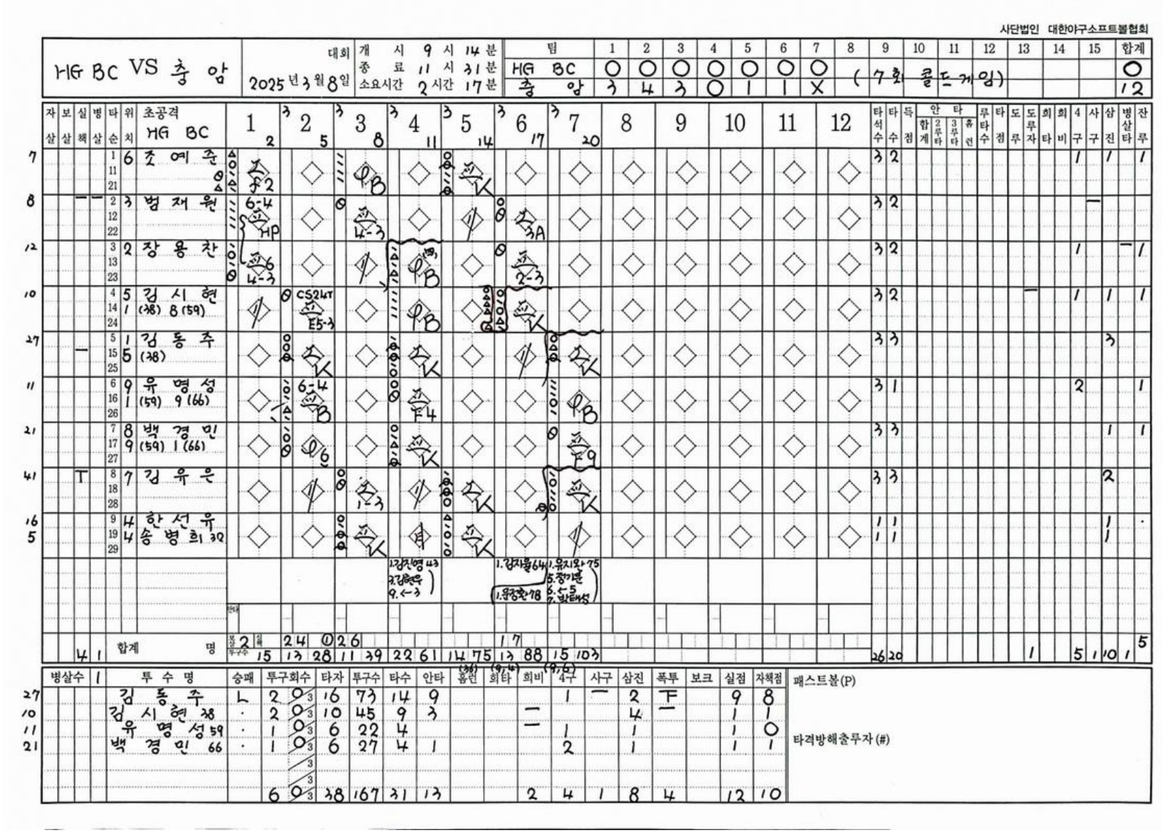
구현 시 문제점 & 해결방안 1

문제	주자 상황이 제공되는 기록지는 수기 기록지로써, IMG 형태의 기록지로만 존재 (다음 장 참고)
원인 분석	국내 고교야구는 KBO Trackman, MLB Hawkeye 시스템과 달리 자동 수집 인프라가 부재 → KBSA 협회는 IMG로만 보관하며, 외부 연구자가 활용 가능한 정형 데이터로 가공되어 있지 않음
해결 방법	기록지를 크롤해 엑셀로 받은 뒤 팀원 4명이 연도·팀을 나눠 손으로 보정 (2020~2026년 7시즌) → 아웃·점수·주자를 코드로 재현해 이닝 요약·타자·투수 공식 기록과 3중 대조, 차이가 0이 될 때까지 반복

104개 팀	11,258명	약 33,000개	6,278경기
2026 시즌 고교팀	7시즌 전체 선수	사이트용 JSON 파일	2020~2026

구현 시 문제점 & 해결방안 1

경기 수기 기록지



사단법인 대한야구소프트볼협회

HG BC VS 충 암

대회 2025년 3월 8일

개 시 9 시 14 분
종 료 11 시 31 분
소요시간 2 시간 17 분

팀	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	합계
HG BC	0	0	0	0	0	0	0	(	7회	콜	드	게	임			0
충 암	3	4	3	0	1	1	X									12

자살	보살	실책	병살	타순	위치	초공격 HG BC	1	2	3	4	5	6	7	8	9	10	11	12	타석수	타수	득점	안타 합계	안타 2루타	안타 3루타	안타 홈런	루타수	타점	도루	도루자	희비	4구	사구	삼진	병살타	잔루
7				1	6	조 예 준													3	2											1		1	1
				11																														
				21																														
8		—	—	2	3	범 재 원													3	2														
				12																														
				22																														
12				3	2	장 용 찬													3	2											1			1
				13																														
				23																														
10				4	5	김 시 현													3	2											1		1	1
				14	1	(38) 8 (59)																												
				24																														
27		—		5	1	김 동 주													3	3											3			
				15	5	(38)																												
				25																														
11				6	9	유 명 성													3	1											2			1
				16	1	(59) 9 (66)																												
				26																														
21				7	8	백 경 민													3	3											1			1
				17	9	(59) 1 (66)																												
				27																														
41		T		8	7	김 유 곤													3	3											2			
				18																														
				28																														
16				9	4	한 선 유													1	1											1			·
5				19	4	송 병 희 30													1	1											1			
				29																														

구현 시 문제점 & 해결방안 2

문제	2027 드래프트 대상 892명 중 지명 81명(9.1%) — 학년마다 지명자는 수십 명뿐 표본이 작아 모델이 지명자를 외우기 쉽고, 화면에 보여 줄 확률은 양끝으로 과신하기 쉬움

해결 방법 비교

X SMOTE 합성 샘플링 (채택 안함)	O 규제 + 연도별 검증 + 확률 보정 (채택)
양성 샘플이 학년마다 수십 명에 불과 → 합성 데이터가 비현실적인 선수 패턴 생성 위험 → 과도한 보간으로 모델 신뢰성 저하 우려 → 실제 선수 스탯 분포를 왜곡할 가능성	얕은 트리(depth 3 · leaf 7) + L1·L2 규제로 과적합 억제 → 연도별 leave-one-out: 한 해를 통째로 빼고 학습해 검증 → OOF 예측으로 Platt 보정 ('90% 이상' 선수의 실제 지명률 78.6%) → AUROC · Precision@K 를 최종 평가 지표로 채택

Accuracy의 함정: 전원을 '미지명'으로 찍어도 90.9% → 지명자를 얼마나 위로 올리는지(AUROC · Precision@K)가 핵심 지표

구현 시 문제점 & 해결방안 3 — 고교야구에 맞는 지표

	문제	해결
wOBA	MLB 상수를 그대로 쓰면 **고교야구 득점 환경**과 어긋남	24가지 주자·아웃 상태의 기대득점(RE24)에서 **선형가중치를 직접 추정**해 wOBA · wRC+ 계산
RE24	한 시즌 표본이 작아 기대득점 표가 흔들림 — **3루타 가치가 홈런보다 크게** 나오는 역전	**상태 전이(마르코프 체인)**로 RE24를 다시 풀어 역전을 바로잡음 · 승부치기는 전용 표
승리확률	경험적 승리확률표가 편향 — **동점인데 홈팀 승률 0.73**	**정규근사 모델**로 대체 — 동점·대칭이면 정의상 0.5, 루상황 보정만 리그 RE로 → WPA · LI

구현 시 문제점 & 해결방안 4 — 서비스 운영

	문제	해결
데이터 보호	JSON을 public/ 에 두면 **URL 하나로 전체 색인**을 통째로 받아 갈 수 있음	data/ 를 **public 밖**으로 옮기고 /api/* 가 정규식 검증 + rate limit 뒤에서 조각만 응답
배포	Vercel 무료 플랜은 **소유자 계정 커밋만** 배포 → 팀원 커밋은 Blocked	**GitHub Actions**가 소유자 토큰으로 lint → 타입 검사 → 배포 — 누가 병합해도 배포
갱신 속도	데이터 갱신(refresh_all) 한 번에 **약 30분** — 같은 엑셀을 수십 번 다시 해석	해석 결과를 **실행 캐시**에 남기고 과거 시즌 단계는 건너뜀 → **약 15분** (2026-10-06 실측)

구현 — 사이트 구성 (rookiezpark.com)

홈	선수	팀	게임피드	드래프트	커뮤니티
• 리더 요약 카드 • 데이터 소개 • 선수 검색	• 리더보드 • 트래킹데이터 • 클러치 • 선수 상세	• 순위 • 팀 기록 • 뎁스차트 • 투구수 관리	• 날짜·대회별 경기 • 이닝별 중계 • 승리확률 흐름	• 신인 드래프트 • 국가대표 • 올스타전 • 해외 구단 입단	• 게시판 • 기록 오류 제보

36개
페이지

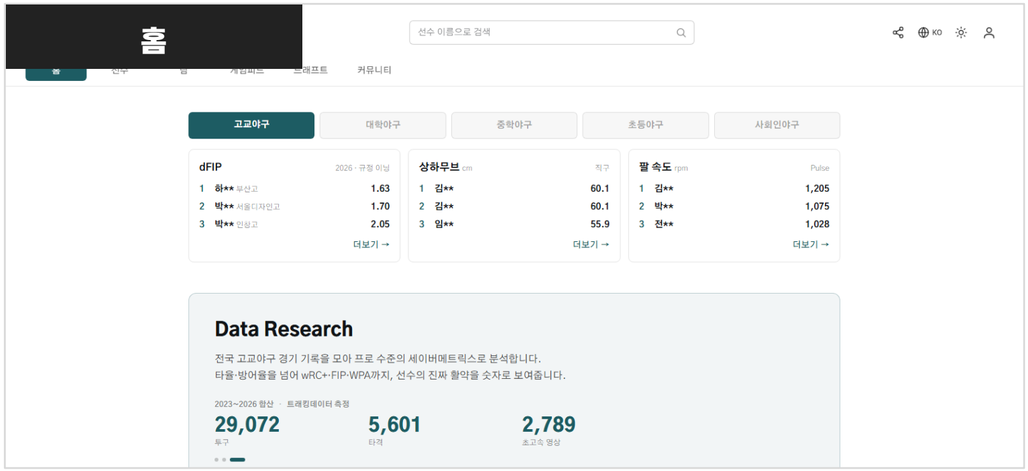
40개
API 라우트

6개 언어
한 · 영 · 일 · 스 · 중(번체·간체)

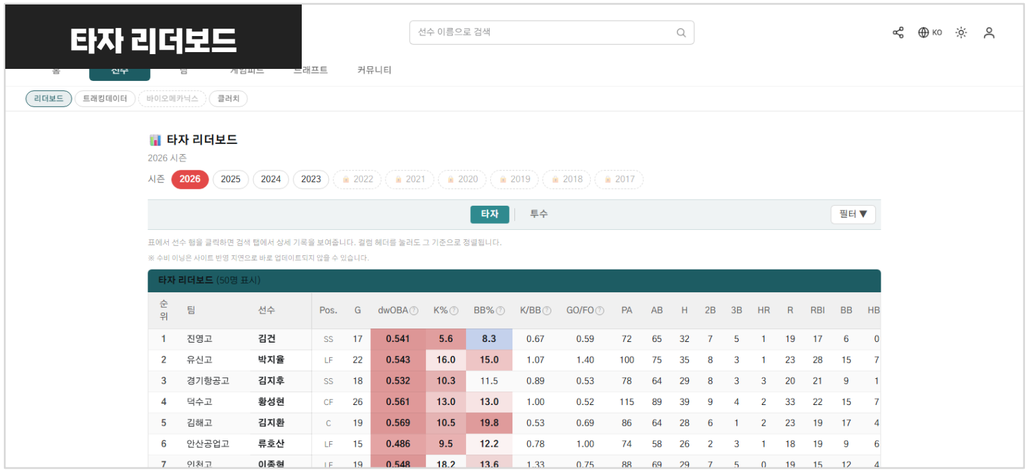
4등급
로그인 권한

구현 — 주요 화면

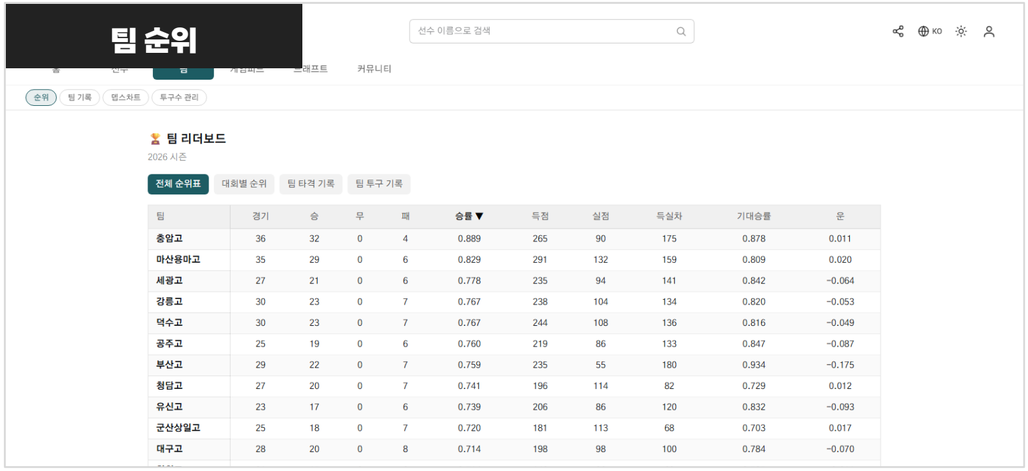
홈



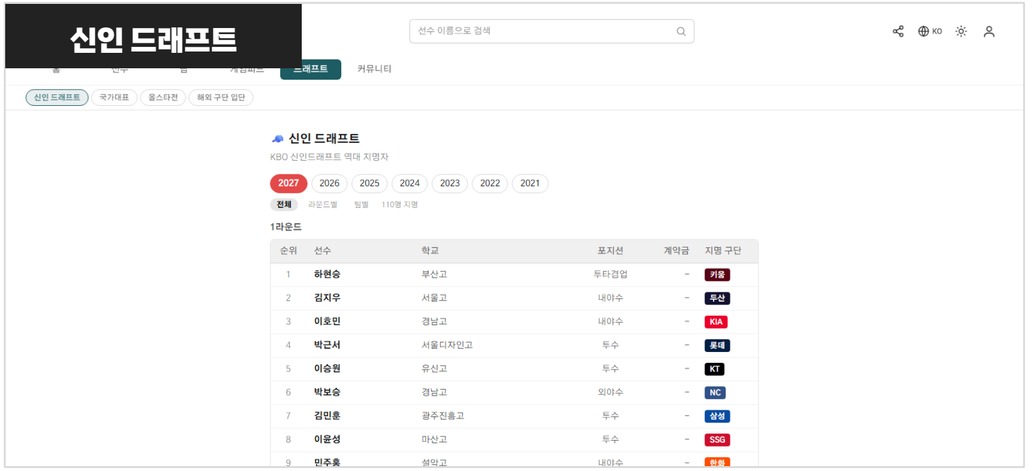
타자 리더보드



팀 순위



신인 드래프트

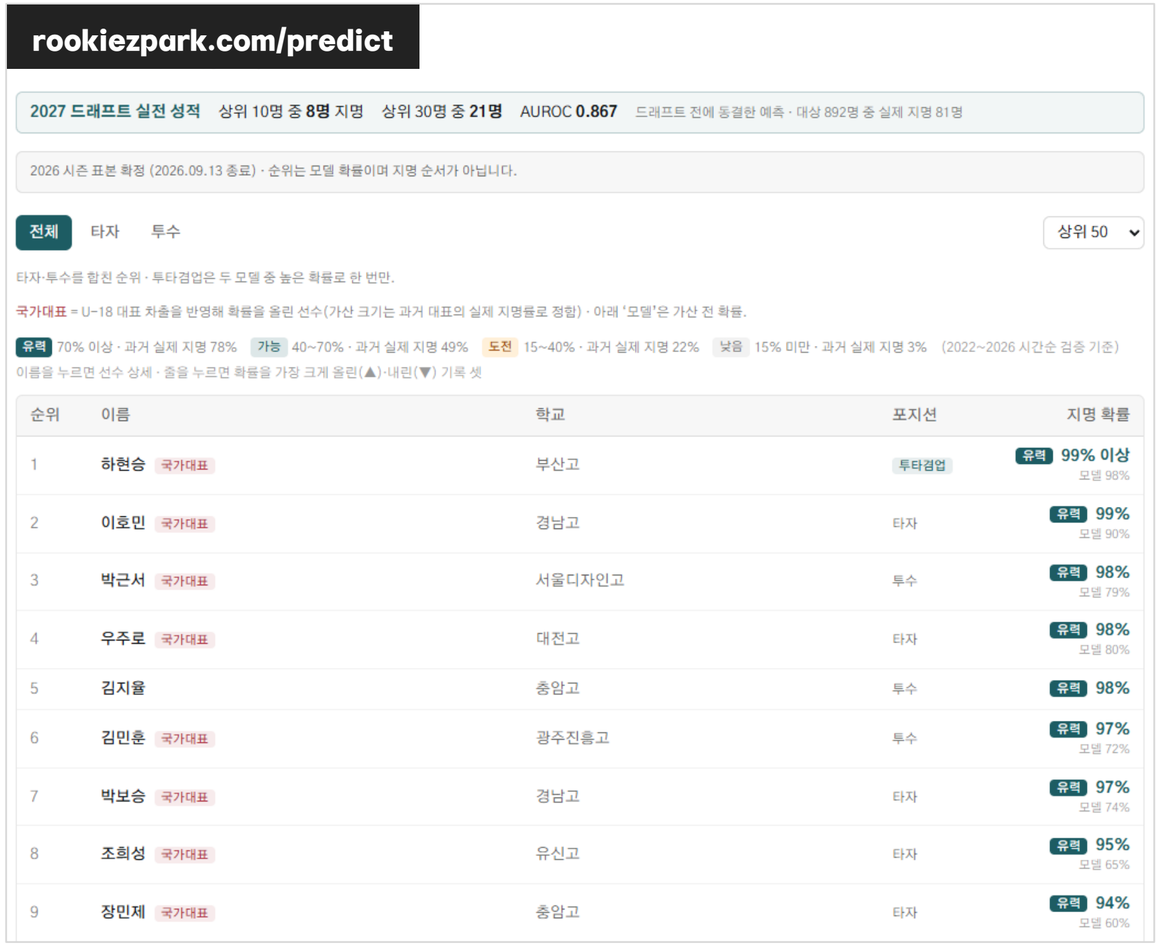


5. 결론



DRAFTLAB

결론 — 선수별 지명 예측 화면



고3 선수 전원의 지명 확률

2026 코호트 889명을 확률 순으로 · 정수 확률 + 유력·가능·도전·낮음 등급(과거 실제 지명 78·49·22·3%)

근거·실전 성적·선수 상세

줄을 누르면 확률을 움직인 기록 3개(SHAP) · 이름을 누르면 선수 상세 · 위에 2027 실전 성적

국가대표 가산을 드러냄

U-18 대표는 과거 대표 결과로 맞춘 로그오즈 가산(타자 +2.4 · 투수 +2.7) · 가산 전 '모델' 확률을 함께 표시

서버에서 잠금

실명 고3 선수의 확률이라 비밀번호 또는 관리자 세션으로만 열람

결론 — 2027 KBO 신인드래프트 실전 검증

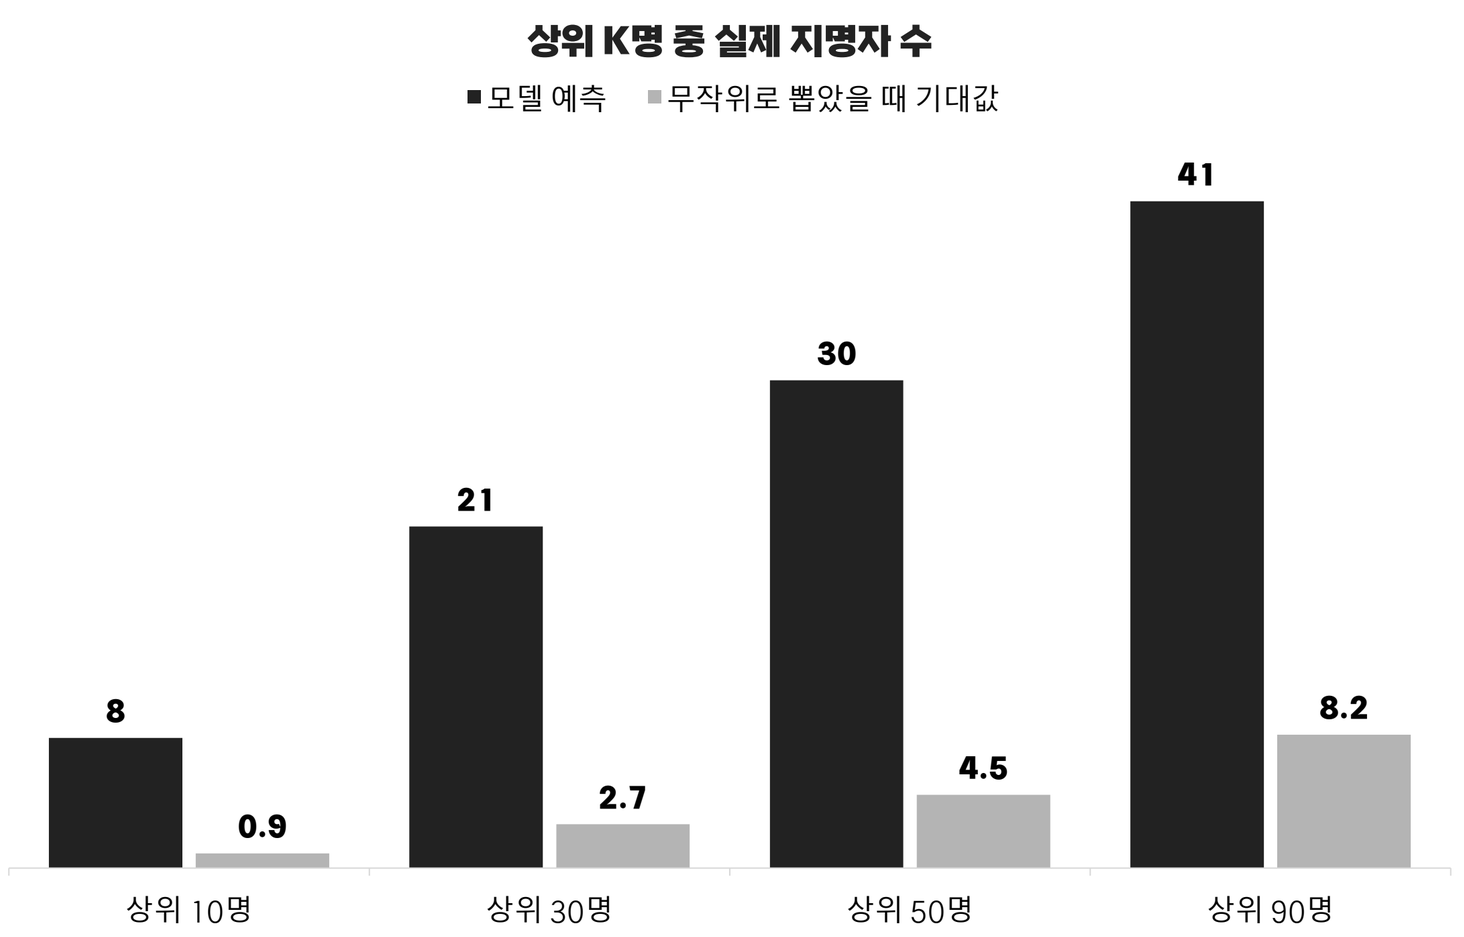
0.867
AUROC · 90% 0.84~0.90

8 / 10
상위 10명 중 지명

21 / 30
상위 30명 중 지명

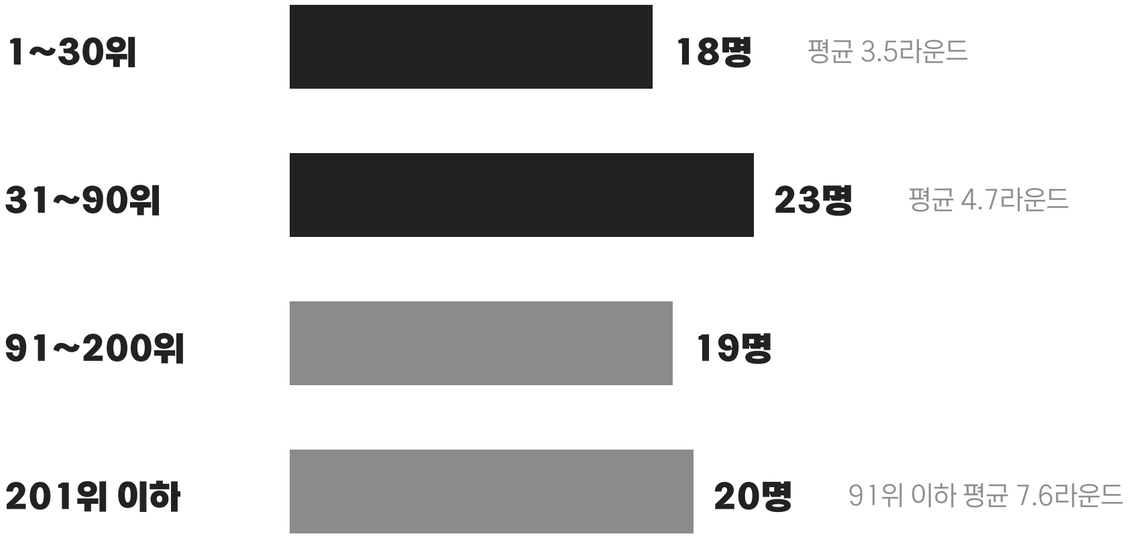
30 / 50
상위 50명 중 지명

대상 **892명** 중 실제 지명 **81명**
드래프트 3일 전(09-18) 동결한 예측을 채점



결론 — 오류 분석 (놓친 지명자는 누구였나)

실제 지명자 80명이 모델 순위 어디에 있었나



맞힌 지명자(1~30위) vs 놓친 지명자(91위 이하) — 같은 학년 안 백분위 중앙값

	맞힌 지명자	놓친 지명자
타자 타석 수	96	72
타자 OPS	89	83
투수 이닝	93	76
투수 FIP (낮을수록 좋음)	상위 2%	상위 35%

놓친 지명자 = 기회가 적고 기록이 평범했던 하위 라운드 지명 — 체격·구속·잠재력처럼 기록지에 없는 정보로 뽑힌 선수들

반대로 모델 상위 30명 중 12명은 지명되지 않음 — 대학 진학·드래프트 미신청 여부는 데이터에 없어 구분 불가

현재 모델(K%oe 포함)을 2020~2025로 학습해 2026 고3 888명을 채점 · 국가대표 가산 없음

결론 — 개선: 국가대표 가산치를 데이터로 정함

방식	검증 AUROC	2027 AUROC	상위 10	상위 30	상위 50	국가대표 확률 → 실제
기존	0.893	0.883	8	17	30	58.6% → 100%
규칙 +1 (동결본 방식)	0.893	0.889	9	19	30	72.1% → 100%
B 가산치를 데이터로	**0.896**	**0.893**	**10**	**21**	**32**	**88.3% → 100%**
A 피처로 학습	0.896	0.893	8	20	31	73.1% → 100%

문제

고3 국가대표는 2022~2026 해마다 76~100% 지명 — 모델은 평균 60% 안팎으로 봄 · 사람이 정한 +1로는 부족

방법 B 채택

학습 코호트(2022~2025) 대표의 보정 확률과 실제 지명으로 로그오즈 가산치를 최대우도로 맞춤 — 예측 학년은 안 씀

결과

가산치 **타자 +2.40 · 투수 +2.70** (이전 +1) · 2027 상위 10명 전원 지명 · 사이트 반영(10-27)

2027은 가산치를 맞출 때 쓰지 않은 해지만 방식을 고를 때는 봤음 → 깨끗한 검증은 2028 드래프트 · 표의 수치는 비교 실험값(사이트 값과 소수 차이)

결론 — 성과와 한계, 향후 과제

성과

사전 예측의 실전 검증
AUROC 0.867, 상위 10명 중 8명 지명

모델 비교 · 해석
지표 하나보다 AUROC +0.08, SHAP으로 근거 분해

타석 단위 7시즌 데이터셋
6,278경기 · 11,258명, 3중 대조 통과

플랫폼으로 공개 · 운영
rookiezpark.com — 예측 동결·채점까지

한계

기록 밖 정보가 없음
놓친 지명자는 평균 7.6라운드 — 체격·구속 판단 영역

확률 상단의 과신
'90% 이상' 14명 중 실제 지명 11명(78.6%)

국가대표 가산은 아직 사후 가산
크기는 2022~2025 결과로 맞췄지만 깨끗한 검증은 2028

사전 동결 채점은 한 해
시간순 검증 5년(0.885~0.939)으로 보완 · 모델 간 우열은 못 가림

향후 과제

기록 외 피처
신장·체중·구속(영상 분석)을 편향 없이 모으기

시즌 중 확률 추이
갱신마다 예측을 기록해 선수별 변화를 그래프로

국가대표를 피처로
대표 표본이 쌓이면 가산 대신 모델이 직접 학습

두 번째 실전 검증
2028 드래프트도 같은 절차로 동결·채점

6. 참고 문헌



DRAFTLAB

참고 문헌

[TVING 한국 VS 호주 다시보기 (8강 진출 사진)]
HTTPS://WWW.TVING.COM/CONTENTS/L00000298230

[DBPIA 고교야구 지명 예측 검색 결과]
HTTPS://WWW.DBPIA.CO.KR/SEARCH/TOPSEARCH?QUERY=%EA%B3%A0%EA%B5%90%EC%95%BC%EA%B5%AC%20%EC%A7%80%EB%AA%85%20%EC%98%88%EC%B8%A1

[MLB 구단, 대학 리그에 TRACKMAN 설치 후 데이터 수집]
HTTPS://BLOGS.FANGRAPHS.COM/MLB-OUTLAWS-AMATEUR-TRACKMAN-DATA-EXCLUSIVITY/

[2023 신인 드래프트 지명 결과]
HTTPS://KO.WIKIPEDIA.ORG/WIKI/2023%EB%85%84_KBO_%EB%A6%AC%EA%B7%B8_%EC%8B%A0%EC%9D%B8_%EB%93%9C%EB%9E%98%ED%94%84%ED%8A%B8

[2024 신인 드래프트 지명 결과]
HTTPS://KO.WIKIPEDIA.ORG/WIKI/2024%EB%85%84_KBO_%EB%A6%AC%EA%B7%B8_%EC%8B%A0%EC%9D%B8_%EB%93%9C%EB%9E%98%ED%94%84%ED%8A%B8

[2025 신인 드래프트 지명 결과]
HTTPS://KO.WIKIPEDIA.ORG/WIKI/2025%EB%85%84_KBO_%EB%A6%AC%EA%B7%B8_%EC%8B%A0%EC%9D%B8_%EB%93%9C%EB%9E%98%ED%94%84%ED%8A%B8

[2026 신인 드래프트 지명 결과]
HTTPS://KO.WIKIPEDIA.ORG/WIKI/2026%EB%85%84_KBO_%EB%A6%AC%EA%B7%B8_%EC%8B%A0%EC%9D%B8_%EB%93%9C%EB%9E%98%ED%94%84%ED%8A%B8

[KBSA(대한야구소프트볼협회) 사이트]
HTTPS://WWW.KOREA-BASEBALL.COM/

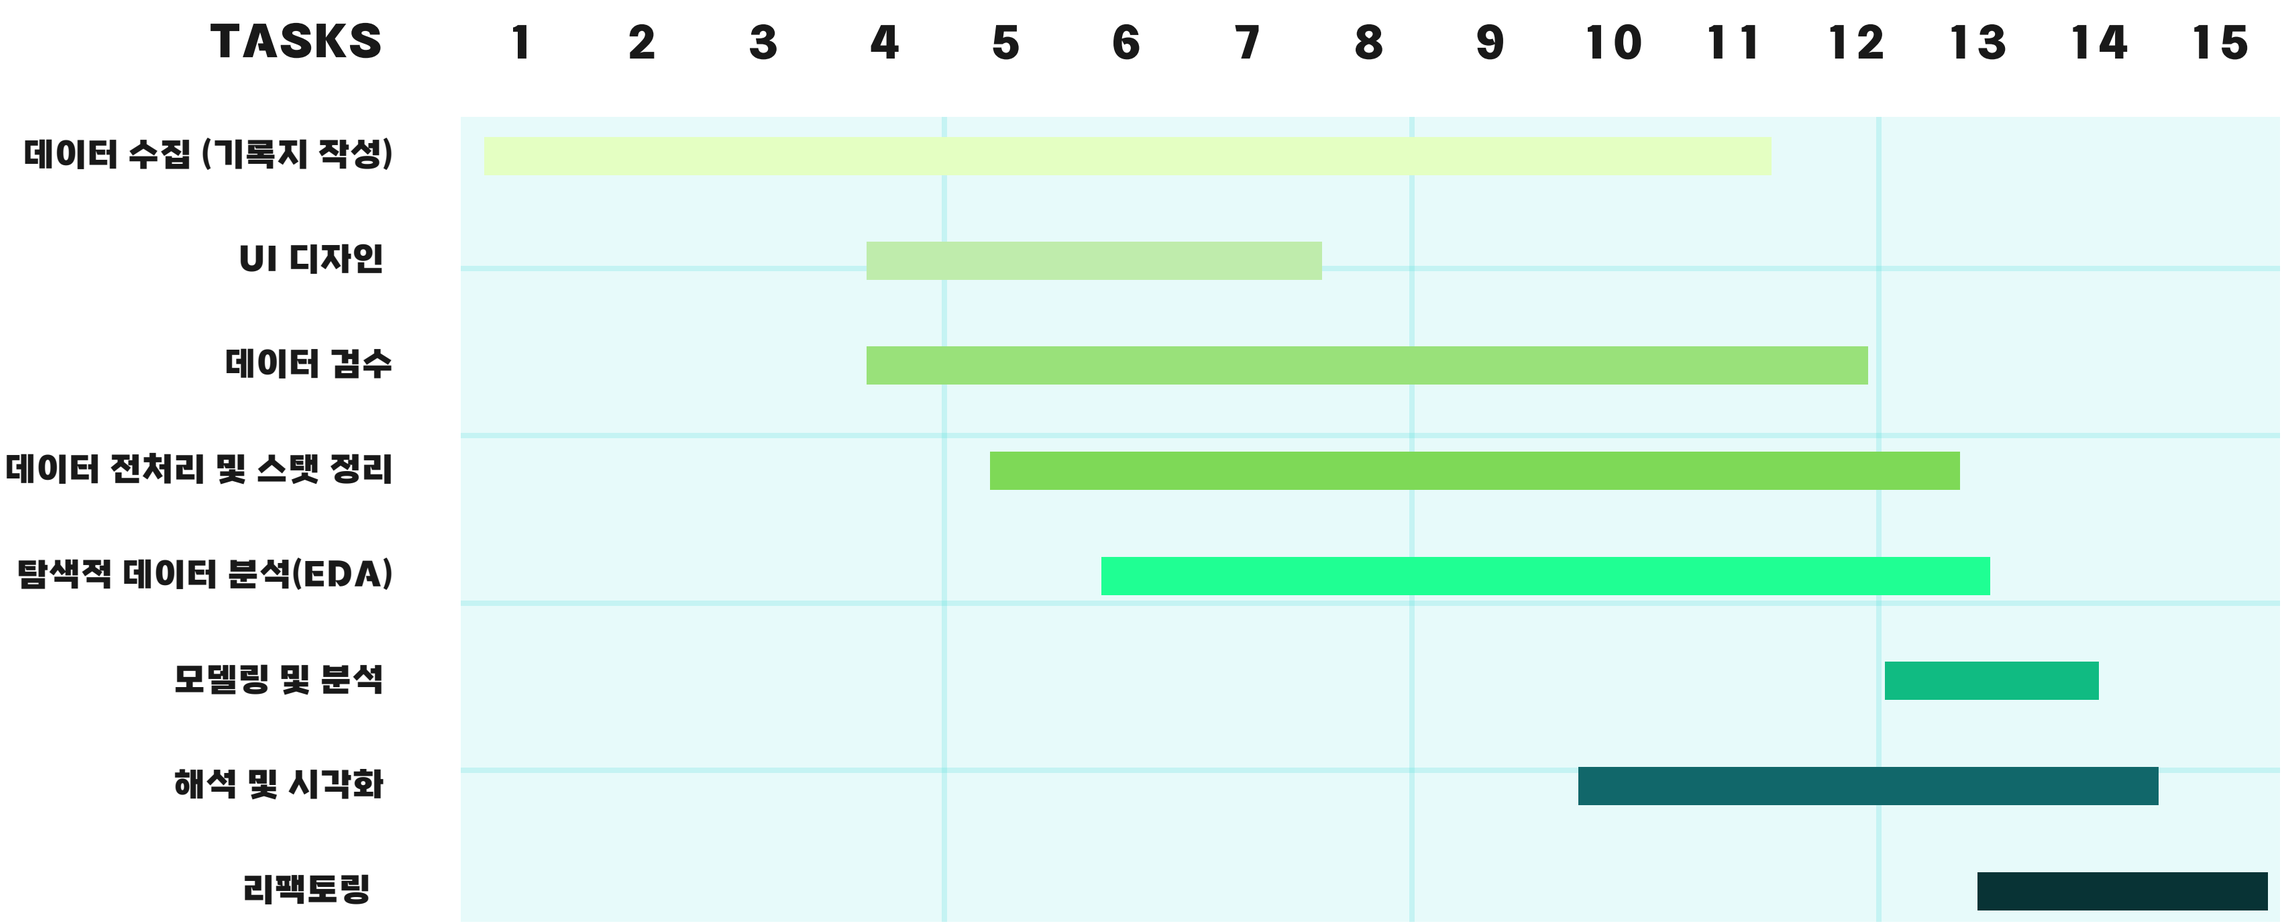
2025 황금사자기 사진]
HTTPS://WWW.KOREA-BASEBALL.COM/BOARD/POST_VIEW?POST_IDX=21215&BOARD_IDX=12&PAGE=2

7. 개발 일정 & 역할 분배



DRAFTLAB

개발 일정 (1학기 — 모델 개발)



DRAFTLAB

개발 일정 (2학기 — 서비스 확장)

2026.07 커밋 288

- 웹 사이트 공개 — 클러치 · 투구수 관리 · 국가대표
- 드래프트 예측 탭 (07-21)
- 영상 분석 실험 시작 (07-29)
- 로그인 도입 (07-31)

2026.08 커밋 200

- 4개 학년으로 예측 학습 (08-07)
- 파크팩터 7시즌 (08-24)
- Colab 원격 갱신 (08-26)
- 주자 추적 불일치 0 (08-30)

2026.09 커밋 217

- 드래프트 입력기 (09-17)
- 예측 자동 동결 (09-18)
- 2027 드래프트 채점 (09-21)
- U-18 국가대표 기록 (09-25)

2026.10 커밋 120

- RE24 마르코프 전환 (10-02)
- 갱신 30분 → 15분 (10-06)
- 6개 언어 지원 (10-17)
- 학교용 경기 기록기 (10-19)
- 국가대표 가산치 (10-27)
- 예측 등급 표시 (10-27)

4개월 · 커밋 825개 (pipeline 334 · web 491) — 서비스를 운영하면서 기능을 계속 더함

DRAFTLAB

역할 분배

류산성

- 주자 상황 생성을 위한 데이터 입력
- 데이터 전처리
- AI 모델링
- TABLEAU 대시보드

마태림

- 주자 상황 생성을 위한 데이터 입력
- 데이터 전처리
- 세이버메트릭스 지표 분포 분석
- 지명 가능성과 지표 관계 체계 제작

표룡희

- BEAUTIFULSOUP을 사용한 데이터 크롤링
- 주자 상황 생성을 위한 데이터 입력
- 세이버매트릭스 스탯 생성 및 재구성
- AI 모델링
- 웹 서비스 · 파이프라인 개발 및 운영

홍록기

- 주자 상황 생성을 위한 데이터 입력
- UI 디자인
- 데이터 검수
- 리팩토링

숫자는 거짓말하지 않는다.
숫자는 경기의 이야기를 담고 있다.
우리는 그것을 해석하는 법을 알아야 할 뿐이다.

- BILL JAMES