졸업작품 최종 보고서

머신러닝 기반 고교야구 선수의 프로 지명 가능성 예측 모델 개발

Rookiezpark

KBSA 기록지 7 시즌으로 지명 예측 모델을 만들고, 웹 플랫폼으로 공개·동결·채점까지 운영했다

Team DRAFT LAB

류산성 · 마태림 · 표룡희 · 홍록기

2026 년 10 월

요약

국내 고교야구에는 MLB 의 Trackman 이나 KBO 의 자동 기록 같은 수집 인프라가 없고, 대한야구소프트볼협회(KBSA)가 공개하는 기록지는 사람이 손으로 쓴 것을 옮긴 형태라 주자 상황 같은 맥락 정보를 그대로 분석에 쓰기 어렵다. 본 프로젝트는 **2020~2026 년 7 시즌, 6,278 경기, 11,258 명**의 기록지를 수집하고, 사람이 보정한 기록을 코드로 다시 재현해 협회 공식 기록과 **3 중 대조**함으로써 타석 단위 데이터셋을 만들었다.

이 데이터 위에 이 리그의 기대득점(RE24)에서 직접 추정한 **리그 맞춤 세이버매트릭스**(wOBA·wRC+·FIP·WPA 등)를 계산하고, LightGBM 으로 고교 3 학년 선수의 **KBO 신인드래프트 지명 확률**을 예측했다. 예측은 드래프트 3 일 전에 동결한 뒤 **2027 KBO 신인드래프트(2026-09-21)** 실제 결과로 채점했고, AUROC 0.867, 상위 10 명 중 8 명 지명이라는 결과를 얻었다.

모델 선택의 근거를 확인하려고 같은 피처·같은 검증으로 다섯 가지 방법을 비교했다. 머신러닝 모델은 OPS·FIP 하나로 줄 세우는 단순 기준선보다 AUROC 가 약 **0.085** 높았지만, 로지스틱 회귀와 LightGBM 사이의 차이는 통계적으로 구분되지 않았다. 성능은 모델 종류보다 **피처 설계**(같은 학년 안 백분위, 고 1·2 성적, 상대 수준 보정 삼진율 K%oe)에서 나왔고, SHAP 분석에서도 타자는 타석 수, 투수는 K%oe 가 가장 큰 근거였다.

모든 결과는 웹 서비스 **rookiezpark.com** 으로 공개해 시즌 중 계속 갱신하고 있으며, 데이터 유출을 막는 접근 구조와 4 등급 로그인, 관리 도구까지 갖춰 실제로 운영하고 있다.

주제어: 고교야구, 머신러닝, 드래프트 예측, LightGBM, SHAP, 세이버매트릭스, RE24, 데이터 검수

1. 서론

1.1 배경과 필요성

- **구단의 투자 규모** — KBO 10 개 구단은 1 차 지명 폐지 후 4 년간 신인 계약금으로 평균 92 억 원을 지불했다. 그만큼 아마추어 선수 평가의 정확도가 중요하다.

- **데이터 기반 스카우팅의 확산** — MLB 구단들은 대학 리그에 Trackman 장비를 설치해 아마추어 선수 데이터를 직접 수집하고 스카우팅에 쓴다.
- **국내 연구의 공백** — DBpia 에서 '고교야구 지명 예측'을 검색하면 논문은 6 건이 전부이고, 표본은 최대 20 명, 쓰인 지표도 ERA·WHIP·피안타율 등 3~4 개에 그친다.

1.2 목표

1. KBSA 기록지를 수집·보정·검수해 **주자 상황이 포함된 타석 단위 데이터셋**을 만든다.
2. 고교야구 득점 환경에 맞춘 **리그 맞춤 세이버매트릭스**를 계산한다.
3. 고교 3 학년 선수의 **드래프트 지명 가능성**을 예측하고, 실제 드래프트 결과로 검증한다.
4. 결과를 누구나 볼 수 있는 **웹 서비스**로 공개하고 시즌 중 계속 갱신한다.

1.3 중간 발표 이후 달라진 점

중간 발표에서는 2020~2025 년 기록으로 학습한 분류 모델과 Streamlit 시연 화면을 보였다. 최종까지 데이터를 2026 시즌으로 넓히고, 모델을 실제 드래프트로 검증하고, 결과를 운영 중인 웹 서비스로 옮겼다.

표 1. 중간 발표와 최종 결과 비교

구분	중간 발표 (DRAFT LAB 모델)	최종 (Rookiezpark 서비스)
데이터	2020~2025 6 시즌	2020~2026 7 시즌, 시즌 중 계속 갱신
검수	G·R·RBI 교차 검증	이닝 요약·타자·투수 공식 기록 3 중 대조 (차이 0 까지)
지표	타율·OPS·FIP 등 일반 지표	이 리그 RE24 로 추정한 wOBA·wRC+·WPA
모델 검증	교차 검증(OOF)	드래프트 전 예측 동결 → 실제 결과로 채점
결과물	Streamlit 시연 화면	웹 서비스 rookiezpark.com + 관리 도구

2. 관련 연구와 차별성

기존 국내 연구는 투수와 타자를 따로 다루고, 몇 개의 전통 지표만으로 소수 선수를 분석했다. 주자 상황을 반영한 연구나 드래프트 지명 자체를 예측한 연구는 찾지 못했다.

표 2. 기존 연구와 본 프로젝트 비교

구분	기존 연구	본 프로젝트
대상	투수, 타자 별도	투수 + 야수 (투타겸업 통합)
활용 지표 수	3~4 개	30 개+ (예측 피처: 타자 25 · 투수 14)
주자 상황	미포함	타석마다 1·2·3 루 주자 추적
드래프트 예측	없음	핵심 목표
검증 방식	없음	사전 동결 → 실제 드래프트로 채점
샘플 수	6 ~ 20 명	11,258 명 (7 시즌 6,278 경기)
데이터 출처	KBSA 일부	KBSA 기록지 전수 + 공식 기록 대조
결과 활용	논문	웹 서비스 rookiezpark.com

3. 설계

3.1 전체 구조

경기 하나가 사이트에 뜨기까지는 다섯 단계를 거친다. 사람이 고친 기록지가 이 시스템의 원료이고, 검수에서 차이가 0 이 되어야만 다음 단계로 넘어간다.

표 3. 파이프라인 단계

단계	실행 위치	하는 일	산출물
① 수집	Google Colab	KBSA 기록지·박스스코어 크롤	기록지 xlsx(10 경기씩), 박스스코어
② 보정·검수	사람(엑셀) + Colab	기록지 보정 → 재현 → 3 중 대조	full_tracked → season_full
③ 스탯 엔진	로컬 PC · lib/	wOBA·wRC+·FIP·RE24·WPA 계산	선수·팀 지표
④ 익스포트	로컬 PC · scripts/	refresh_all.py 13 단계로 JSON 굽기	JSON 약 33,000 개(440MB)
⑤ 공개	Vercel	Next.js 서버 렌더 + /api/*	rookiezpark.com



그림 1. 시스템 구성과 사이트가 바뀌는 세 가지 길

저장소는 둘이다. **highschool-stats-pipeline** 은 노트북·스탯 엔진·익스포트 스크립트를, **highschool-stats-web** 은 Next.js 앱과 구운 JSON 을 담는다. 구운 JSON 이 web 저장소에 함께 커밋되므로 웹 개발자는 Drive 자격증명 없이 클론만으로 실데이터를 받는다. 사이트가 바뀌는 길은 코드 변경(병합 후 16~20 분), 기록 데이터 갱신(굽기 약 15 분 + 배포), 관리 화면의 운영 데이터(저장 즉시) 세 가지다.

3.2 데이터 검수 — 3 중 대조

크롤 원본을 작업자가 먼저 손으로 보정하고, 그 결과를 코드가 받아 아웃·점수·주자를 처음부터 재현한다. 재현한 값을 협회 공식 기록 세 가지와 비교해 차이가 남으면 보정 단계로 되돌아간다.



그림 2. 데이터 검수 흐름과 3 중 대조

- **전처리** — 표기 정규화, 타석 번호 재정의(개명·등번호 변경 반영), 비타석 행 채우기와 투수 이어 채우기
- **주자 추적** — 타석마다 1·2·3 루 주자(타순 번호)와 득점을 재현. 부정위 타순처럼 규칙으로 못 푸는 예외는 별도 표로 넣는다
- **3 중 대조** — ① 이닝별 아웃·점수 vs 이닝 요약, ② 타자 성적 vs 타자 박스스코어, ③ 투수 성적 vs 투수 박스스코어
- **마감** — 몰수경기 등 결과 전용 경기를 합치고 선수 번호를 붙여 시즌 통합 데이터(season_full)를 parquet 으로 저장

2026-08-30 기준 7 시즌 전체에서 주자 추적 불일치는 0 건이다.

3.3 스탯 엔진

스탯 엔진(lib/)은 프레임워크에 의존하지 않는 순수 pandas 모듈로, 시즌 통합 데이터 한 장을 받아 거의 모든 지표를 만든다. 핵심은 MLB 상수를 빌려 쓰지 않고 **이 리그의 데이터에서 계수를 직접 추정**한다는 점이다.

표 4. 주요 지표와 계산 방식

지표	계산 방식
wOBA · wRC+	24 가지 주자·아웃 상태의 기대득점(RE24)에서 선형가중치를 직접 추정
FIP	IP·HR·BB·K 는 공식 박스스코어 값, 상수는 리그에서 적합
RE24	상태 전이(마르코프 체인)로 풀어 표본이 작을 때의 역전을 방지, 승부치기는 전용 표
승리확률 · WPA · LI	정규근사 모델 — 동점·대칭이면 정의상 0.5, 루상황 보정만 리그 RE
투구수 규정	KBSA 규정(하루 105 구, 구간별 의무 휴식일, 3 일 연속 금지)을 코드로 옮김

3.4 드래프트 예측 모델

고교 3 학년 선수가 그해 KBO 신인드래프트에서 지명될지를 맞히는 이진 분류다. 학습 데이터는 '3 학년 성적과 드래프트 결과가 모두 있는 해'를 원본에서 자동으로 골라 만들고(2027 예측 기준 2020~2025), 레이블도 매번 드래프트 원본에서 새로 생성한다.

표 5. 예측 피처 (모두 같은 학년 안의 백분위)

구분	타자 25 개	투수 14 개
비율 지표	AVG·OBP·SLG·OPS·IsoP·IsoD·K%·BB%·BABIP·HR%·XBH% (11)	ERA·WHIP·FIP·BAA·K/9·BB/9·HR/9·K%·BB%·K/BB (10)
기회량	타석 수 PA (1)	이닝 IP (1)
추가	이전 학년(고 1·고 2) 누적 성적 (13)	상대 타자 수준·전국대회 비율 (2), K%oe (1)

- **같은 학년 안 백분위** — 해마다 리그 환경과 경기 수가 달라도 같은 눈금으로 비교한다. 표본이 작은 선수는 리그 평균 쪽으로 축소한다(PA 100 / IP 30, 최소 50 타석).
- **얕은 트리와 규제** — depth 3, leaf 7, 300 그루에 L1·L2 규제를 걸어 학년마다 수십 명뿐인 지명자를 외우지 않게 한다.
- **연도별 leave-one-out 검증** — 한 해를 통째로 빼고 학습해, 처음 보는 학년을 맞히는 실제 상황과 같게 검증한다.
- **Platt 확률 보정** — OOF 예측으로 확률 눈금만 맞춘다. 단조 변환이라 순위와 AUROC 는 그대로다.

- **환경 피처는 투수에만** — 상대 수준과 전국대회 비율을 함께 넣으면 투수 AUROC 가 0.850 → 0.893 으로 올랐고(95% CI 가 0 을 포함하지 않음), 타자에는 효과가 없었다.

평가는 Accuracy 대신 **AUROC** 와 **Precision@K**(상위 K 명 중 실제 지명자 수)로 한다. 2027 드래프트 대상 892 명 중 지명은 81 명(9.1%)이라, 전원을 '미지명'으로 찍어도 Accuracy 가 90.9%가 되기 때문이다. 또한 예측은 **드래프트 전에 파일로 동결**하고, 결과를 본 뒤 만든 모델은 사후 분석으로 따로 보관해 사전 예측 성적과 섞지 않는다.

3.5 웹 서비스 설계

웹은 계산하지 않고 구운 JSON 을 보여주기만 한다. 설계의 목적은 **데이터를 통째로 가져갈 수 없게 하는 것**이다.

- JSON 은 public 폴더 밖(web/data)에 두어 URL 로 직접 받을 수 없게 하고, 서버에서만 읽는다.
- 브라우저는 /api/* 라우트가 잘라 준 조각만 받는다. 모든 라우트는 입력을 정규식으로 검증하고 IP 별 rate limit 을 건다(저장소 장애 시에는 사이트가 죽지 않도록 통과시키는 fail-open).
- 실명 고 3 선수의 지명 확률은 서버 번들에만 넣고, 비밀번호 또는 관리자 세션으로만 연다.

표 6. 로그인 등급

등급	들어오는 법	볼 수 있는 것 · 할 수 있는 것
비로그인	—	공개 시즌(2023~2026)의 모든 기록
일반 사용자	구글 로그인	+ 기록 오류 제보, 커뮤니티 글쓰기, 즐겨찾기
파트너	발급 계정	+ 비공개 선수, 과거 시즌, 구장 파크팩터
관리자	발급 계정	+ 관리 화면, 드래프트 예측, 데이터 반출

4. 구현

4.1 개발 환경

표 7. 개발 환경

영역	사용 기술
언어 · 런타임	Python 3.12 (Google Colab · 로컬 PC), TypeScript
데이터 처리	pandas 3.0, numpy, pyarrow(parquet), openpyxl
머신러닝	LightGBM 4.7, scikit-learn, statsmodels
웹	Next.js 16, React 19, Tailwind CSS 4
배포 · CI	Vercel, GitHub Actions (lint → 타입 검사 → 배포)
저장소	Google Drive(원본), Upstash Redis(운영 데이터), GitHub 비공개 저장소 2 개

4.2 데이터 규모

표 8. 시즌별 선수 수

시즌	2020	2021	2022	2023	2024	2025	2026
선수 수	3,084	3,164	3,359	3,675	3,915	4,012	3,874

7 시즌 합계 6,278 경기, 중복을 뺀 선수 11,258 명이며, 2026 시즌 기준 104 개 팀이 있다.

사이트용으로 구운 JSON 은 약 33,000 개다.

4.3 구현 중 문제와 해결

① 정형 데이터의 부재

문제 — 주자 상황이 담긴 기록지는 수기 기록지 이미지로만 존재하고, 외부 연구자가 쓸 정형 데이터가 없다.

해결 — 기록지를 크롤해 엑셀로 받은 뒤 팀원 4 명이 연도·팀을 나눠 손으로 보정했다.

아웃·점수·주자를 코드로 재현해 공식 기록과 3 중 대조하고, 차이가 0 이 될 때까지 반복했다.

② 클래스 불균형과 과신

문제 — 학년마다 지명자는 수십 명뿐(2027: 892 명 중 81 명)이라 모델이 지명자를 외우기 쉽고, 확률이 양끝으로 과신된다.

해결 — 합성 샘플링(SMOTE)은 비현실적인 선수 패턴을 만들 수 있어 쓰지 않았다. 대신 얕은 트리와 규제, 연도별 검증, Platt 보정을 썼다. 보정 전 '90% 이상'이라고 한 선수의 실제 지명률은 78.6%였다.

③ 고교야구에 맞지 않는 상수

문제 — MLB 상수는 고교 득점 환경과 어긋나고, 한 시즌 표본으로 만든 RE24 는 3 루타 가치가 홈런보다 크게 나오는 역전이 있었다. 경험적 승리확률표는 동점에서 홈팀 0.73 으로 편향됐다.

해결 — 선형가중치를 리그 RE24 에서 직접 추정하고, RE24 를 상태 전이(마르코프)로 다시 풀었으며, 승리확률은 정규근사 모델로 바꿨다.

④ 서비스 운영

문제 — JSON 을 public 에 두면 전체 색인이 유출되고, Vercel 무료 플랜은 소유자 커밋만 배포하며, 데이터 갱신 한 번에 30 분이 걸렸다.

해결 — 데이터를 public 밖으로 옮겨 API 뒤에 두고, GitHub Actions 가 소유자 토큰으로 배포하게 했으며, 엑셀 해석 캐시와 과거 시즌 건너뛰기로 갱신을 약 15 분으로 줄였다.

4.4 웹 서비스

rookiezpark.com 은 36 개 페이지와 40 개 API 라우트로 이뤄져 있고, 6 개 언어(한국어·영어·일본어·스페인어·중국어 번체·간체, 주소 앞에 /en·/ja 등)와 4 등급 로그인을 지원한다.

표 9. 사이트 메뉴 구성

메뉴	하위 화면
선수	리더보드, 트래킹데이터, 클러치, 선수 상세
팀	순위, 팀 기록, 뎁스차트, 투구수 관리
게임피드	날짜·팀·대회별 경기, 이닝별 중계, 승리확률 흐름
드래프트	신인 드래프트, 국가대표, 올스타전, 해외 구단 입단
커뮤니티	게시판, 기록 오류 제보
관리 도구	명단·드래프트 입력, KBSA 공식 기록 대조, 계정 발급, 오프라인 드래프트 입력기

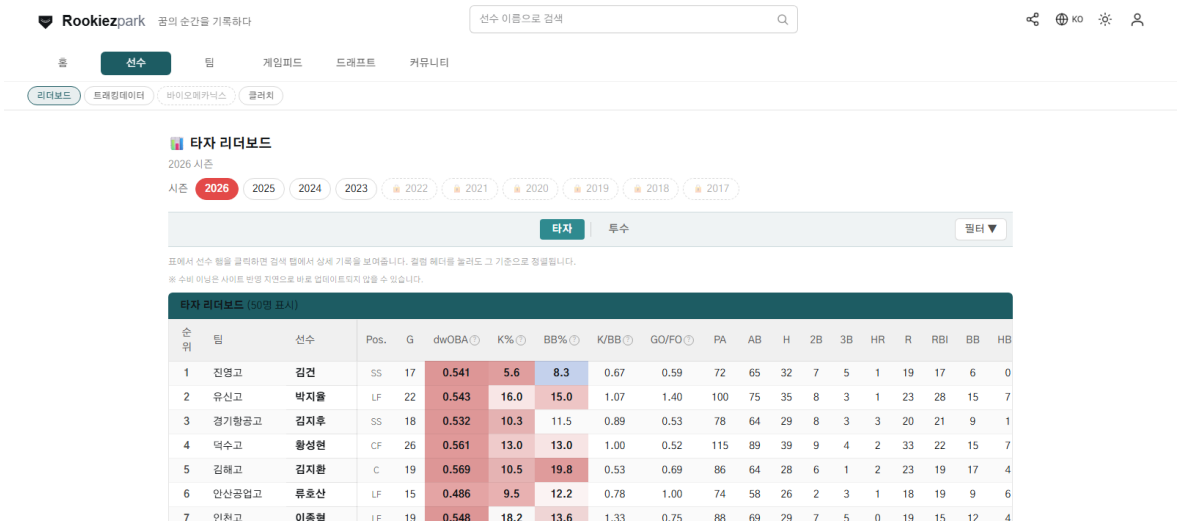
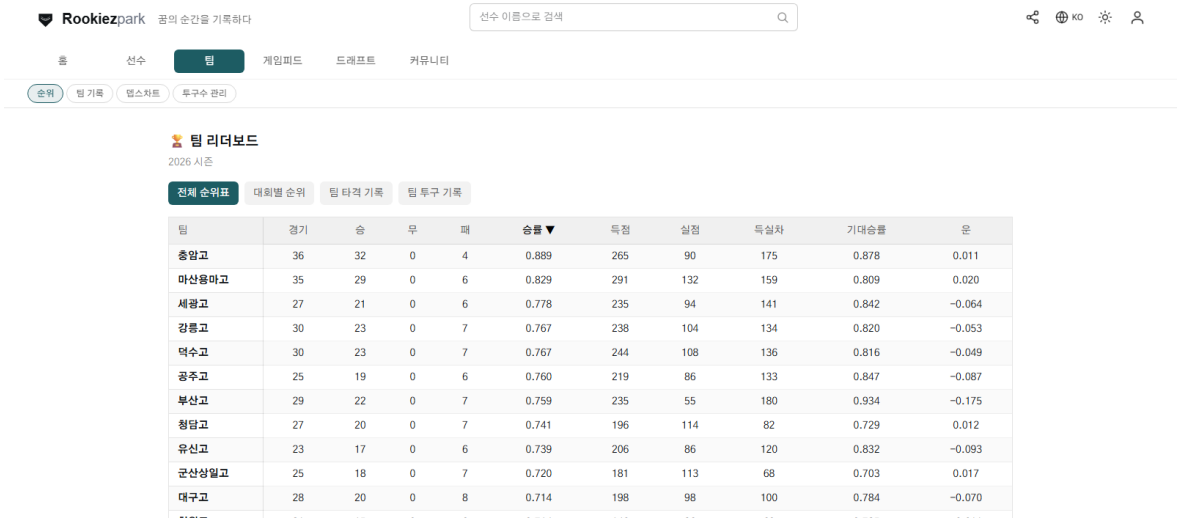


그림 3. 타자 리더보드 — 리그 안 순위를 색으로 표시



팀	경기	승	무	패	승률▼	득점	실점	득실차	기대승률	운
충암고	36	32	0	4	0.889	265	90	175	0.878	0.011
마산용마고	35	29	0	6	0.829	291	132	159	0.809	0.020
세광고	27	21	0	6	0.778	235	94	141	0.842	-0.064
강릉고	30	23	0	7	0.767	238	104	134	0.820	-0.053
덕수고	30	23	0	7	0.767	244	108	136	0.816	-0.049
공주고	25	19	0	6	0.760	219	86	133	0.847	-0.087
부산고	29	22	0	7	0.759	235	55	180	0.934	-0.175
청담고	27	20	0	7	0.741	196	114	82	0.729	0.012
유신고	23	17	0	6	0.739	206	86	120	0.832	-0.093
군산상일고	25	18	0	7	0.720	181	113	68	0.703	0.017
대구고	28	20	0	8	0.714	198	98	100	0.784	-0.070

그림 4. 팀 순위 — 득실차로 계산한 기대승률과 운(실제 승률 − 기대승률)

5. 결과 및 결론

5.1 2027 KBO 신인드래프트 실전 검증

2026-09-18 에 동결한 예측을 2026-09-21 드래프트 결과로 채점했다. 대상은 최소 표본을 넘긴 3 학년 892 명, 그중 실제 지명은 81 명이다.

표 10. 상위 K 명 중 실제 지명자 수

상위 K 명	10 명	30 명	50 명	90 명
모델 예측	8 명	21 명	30 명	41 명
무작위 기대값	0.9 명	2.7 명	4.5 명	8.2 명

AUROC 는 **0.867**(선수 단위 부트스트랩 90% 구간 0.836~0.901, 국가대표 가산 전 0.862)로, 예측 당시 교차 검증 값 0.886 과 큰 차이가 없었다. 상위 10 명 중 8 명이 실제로 지명돼 무작위로 뽑을 때보다 약 9 배 많이 맞혔다.

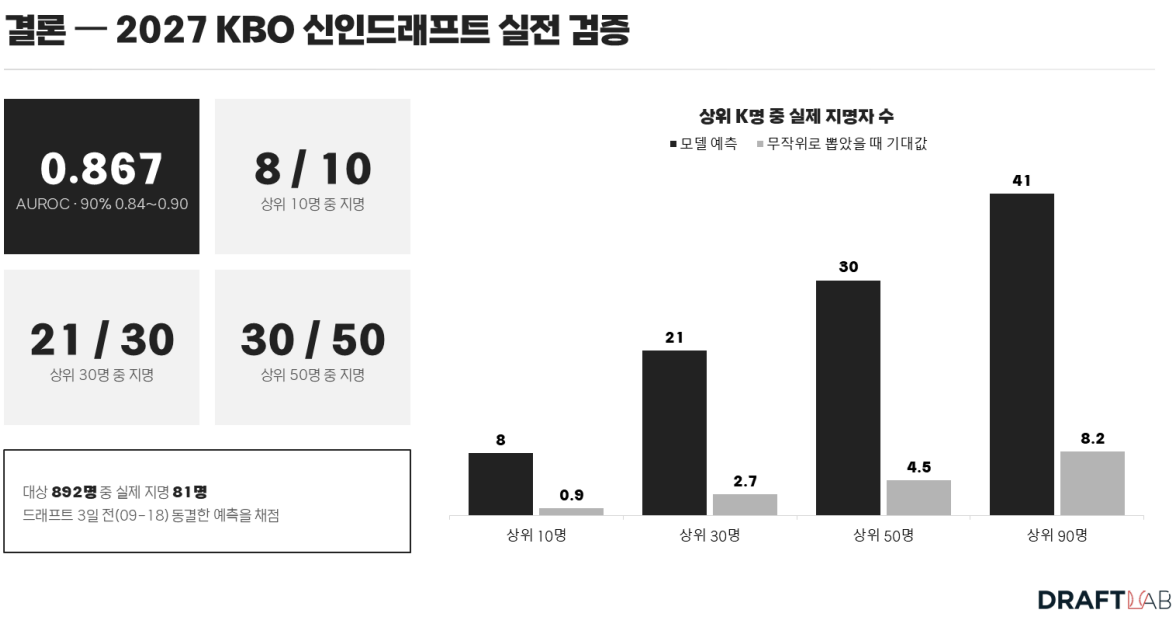


그림 5. 2027 KBO 신인드래프트 실전 검증 결과

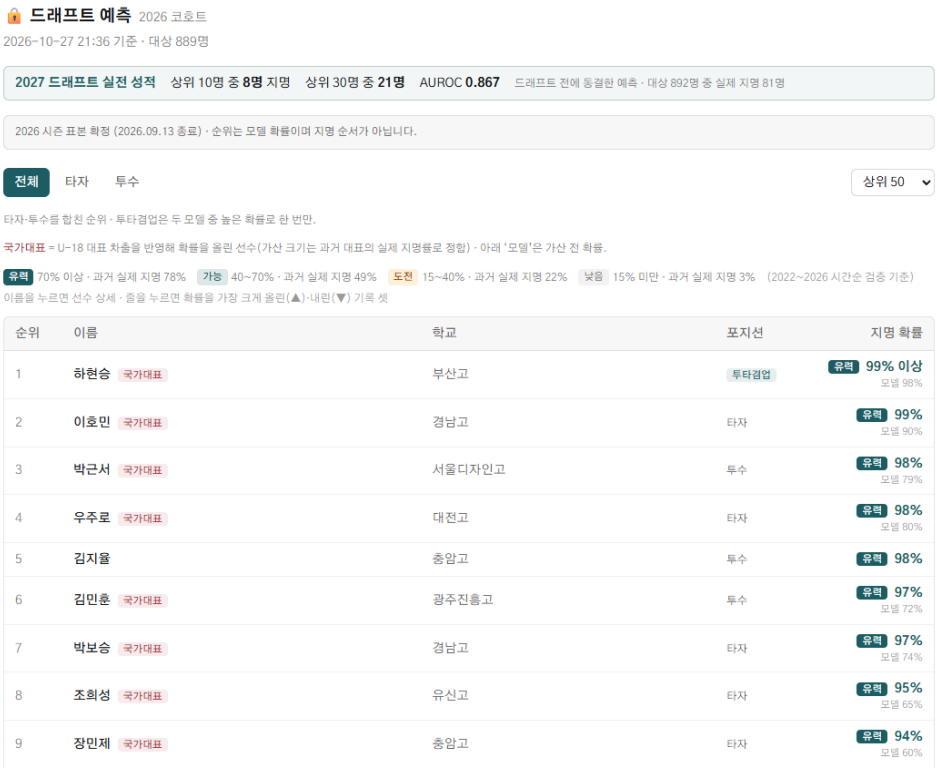


그림 6. 선수별 지명 예측 화면 (2026 코호트 · 2026-10-27 기준, 비밀번호 잠금)

사이트의 예측 화면은 고 3 선수 전원을 확률 순으로 보여준다. 확률 상단이 과신된다는 점(5.7 절)을 반영해 소수점 없이 정수로 반올림하고, 유력(70% 이상)·가능(40~70%)·도전(15~40%)·낮음(15% 미만) 등급을 붙인다. 시간순 검증(2022~2026)에서 각 등급의 실제 지명률은 78%·49%·22%·3%였다. 줄을 누르면 확률을 가장 크게 움직인 기록 세 개(SHAP)와 같은 학년 안 순위가 펼쳐지고, 이름을 누르면 선수 상세로 넘어가며, 화면 위에는 지난 드래프트의 실전 성적을 한 줄로 둔다. 투타겸업 선수는 두 모델 중 높은 확률을 쓰고, U-18 국가대표는 가산 전 모델 확률을 함께 표시한다. 실명 선수의 확률이라 서버에서 잠그고 비밀번호나 관리자 세션으로만 연다.

5.2 연도별 검증과 시간순 검증

드래프트 전에 동결한 모델의 연도별 leave-one-out 결과다. 6 개 학년 중 하나를 통째로 빼고 학습한 뒤 뺀 학년을 예측하는 일을 6 번 반복했다. 같은 학년 선수가 학습과 검증에 섞이지 않아, 내년 선수를 처음 보고 예측하는 실제 사용 조건과 같다.

표 11. 연도별 leave-one-out 결과 (동결 시점 모델)

고 3 시즌	대상	지명	AUROC	타자	투수	상위 10	상위 30	상위 50
2020	804	80	0.847	0.774	0.915	9	19	29
2021	818	90	0.863	0.868	0.854	9	20	29
2022	816	91	0.905	0.899	0.908	10	26	35
2023	794	80	0.887	0.892	0.882	10	20	32
2024	848	93	0.938	0.928	0.948	10	28	43
2025	919	93	0.875	0.874	0.876	8	23	35
전체	4999	527	0.886	0.872	0.895	9.3	22.7	33.8

학년마다 AUROC 가 0.85~0.94 로 고르게 나와 특정 연도에만 맞는 모델이 아니며, 상위 10 명 중 평균 9.3 명이 실제로 지명됐다.

다만 leave-one-out 은 2021 년을 예측할 때 2022~2025 년도 학습에 쓰므로 미래 데이터가 섞인다. 그래서 그 해보다 앞선 시즌으로만 학습해 앞으로만 굴리는 **시간순 검증**을 따로 했다.

2 년치(2020~2021)로 학습한 2022 부터 2020~2025 로 학습한 2026(2027 드래프트)까지 다섯 해다.

표 12. 시간순 검증 — 그 해보다 앞선 시즌으로만 학습 (90% 구간은 선수 단위 부트스트랩)

시험 학년	학습	AUROC	90% 구간	상위 10	상위 30	상위 50	기준선
2022	2020~2021	0.885	0.855~0.913	9	22	34	0.798
2023	2020~2022	0.888	0.855~0.917	10	22	33	0.809
2024	2020~2023	0.939	0.918~0.958	10	29	44	0.856
2025	2020~2024	0.886	0.855~0.916	8	25	36	0.819
2026	2020~2025	0.888	0.860~0.915	8	18	30	0.798

다섯 해 모두 AUROC 0.885 이상이었고 해마다 지표 하나(OPS·FIP) 기준선보다 0.07~0.09 높았다. 랜덤 시드 10 개로 다시 돌린 AUROC 의 표준편차는 해마다 0.0016 이하라 결과가 우연에 기대지 않는다.

5.3 다른 모델과의 비교

LightGBM 을 고른 근거를 확인하려고 같은 피처(타자 25 · 투수 14)와 같은 검증으로 다섯 가지 방법을 비교했다. 단순 기준선은 타자는 OPS, 투수는 FIP 하나로 순위를 매긴 것이다. 2027 실전은

2020~2025 로 학습해 2026 고 3 888 명(지명 80 명, 해외 계약자 제외)을 채점했으며 국가대표 가산은 넣지 않았다. 표의 LightGBM(최종)은 드래프트 뒤 K%oe 를 더한 현재 모델이라 동결본 성적(0.867)과 다르다.

표 13. 모델 비교 — 왼쪽 넷은 연도별 검증 평균, 오른쪽 넷은 2027 실전 (10·30·50 명 = 상위 K 명 중 실제 지명자 수)

모델	AUROC	10 명	30 명	50 명	AUROC	10 명	30 명	50 명
단순 기준선(OPS·FIP)	0.808	6.3	15.2	24.0	0.798	8	17	23
로지스틱 회귀	0.897	8.8	23.3	34.0	0.901	7	18	28
랜덤포레스트	0.887	8.8	23.8	34.2	0.886	7	22	32
LightGBM (1 학기 설정)	0.880	9.2	22.8	32.7	0.874	7	19	30
LightGBM (최종)	0.893	9.5	23.8	35.0	0.888	8	18	30

- **머신러닝은 지표 하나보다 확실히 낫다** — 단순 기준선 대비 AUROC +0.085(선수 단위 페어드 부트스트랩 90% 구간 +0.070~+0.099), 상위 50 명 적중 24.0 → 35.0 명.
- **모델끼리는 차이가 작다** — 로지스틱 회귀와의 차이는 -0.010~+0.002 로 0 을 포함하고, 2027 실전에서는 로지스틱 회귀가 0.901 로 가장 높았다. 성능의 대부분은 모델 종류가 아니라 피처 설계에서 나온다는 뜻이다.
- **그래도 LightGBM 을 쓰는 이유** — 고 1·2 기록이 없는 선수(결측)를 0 이나 중앙값으로 채우지 않고 그대로 다루며, 연도별 검증의 상위 10 명 적중이 가장 높았다(9.5 명). 1 학기 설정(depth 6 · 1000 그루 · 균형 가중치)보다 AUROC 가 +0.008~+0.018 높아, 얕은 트리와 규제로 바꾼 판단도 수치로 확인됐다.

5.4 피처 설계 검증

피처를 묶음 단위로 하나씩 빼고 같은 검증을 다시 돌려, 각 묶음이 실제로 성능에 기여하는지 확인했다.

표 14. 피처 묶음 제거 실험 (LightGBM)

모델	피처 구성	검증 AUROC	변화	2027 실전	변화
타자	전체 25 개	0.871	기준	0.853	기준
	– 이전 학년 13 개	0.851	-0.019	0.831	-0.022
	– 타석 수	0.849	-0.022	0.849	-0.004
투수	전체 14 개	0.908	기준	0.899	기준
	– 상대 수준·전국대회 비율	0.886	-0.022	0.890	-0.009
	– K%oe	0.898	-0.009	0.878	-0.020
	– 이닝	0.907	-0.001	0.891	-0.007

타자는 '꾸준히 기용됐는가(타석 수)'와 '고 1·2 성적'을 빼면 AUROC 가 0.02 가량 떨어지고, 투수는 '누구를 상대로 던졌는가(상대 수준·전국대회 비율)'를 빼면 0.022 떨어진다. 투수의 이닝 수는 빼도 거의 변화가 없었다.

5.5 모델 해석 — SHAP

LightGBM 에 내장된 TreeSHAP(pred_contrib)으로 각 피처가 예측 로그오즈를 얼마나 움직였는지 계산했다. 2020~2025 전체로 학습한 모델에서 학습 선수 전원의 |SHAP| 평균을 중요도로 썼다.

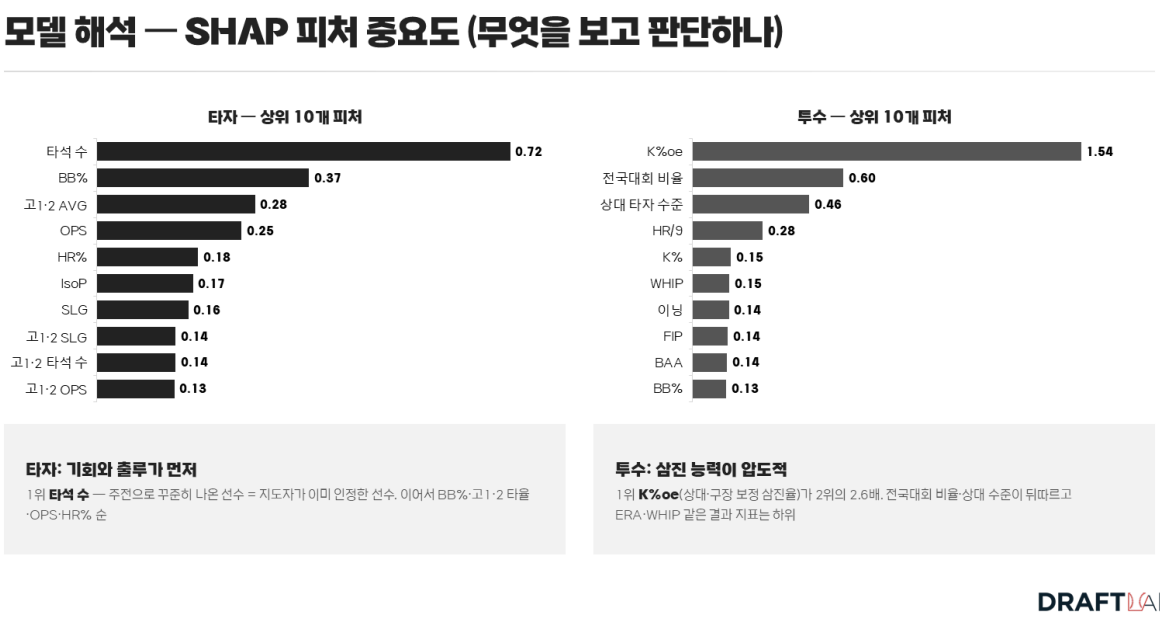


그림 7. SHAP 피처 중요도 — 타자·투수 상위 10 개

타자는 **타석 수**(0.72)가 가장 컸다. 주전으로 꾸준히 나왔다는 것 자체가 지도자가 이미 인정한 선수라는 신호로 읽힌다. 이어서 BB%·고 1·2 AVG·OPS·HR% 순이다. 투수는 상대 타자와 구장을 보정한 삼진율 **K%oe**(1.54)가 2 위 전국대회 비율(0.60)의 2.6 배로 압도적이었고, ERA·WHIP 같은 결과 지표의 비중은 작았다. 다만 전국대회 비율과 상대 수준은 실력이 아니라 '강팀에서 많이 노출됐다'는 효과를 함께 담고 있을 수 있다.

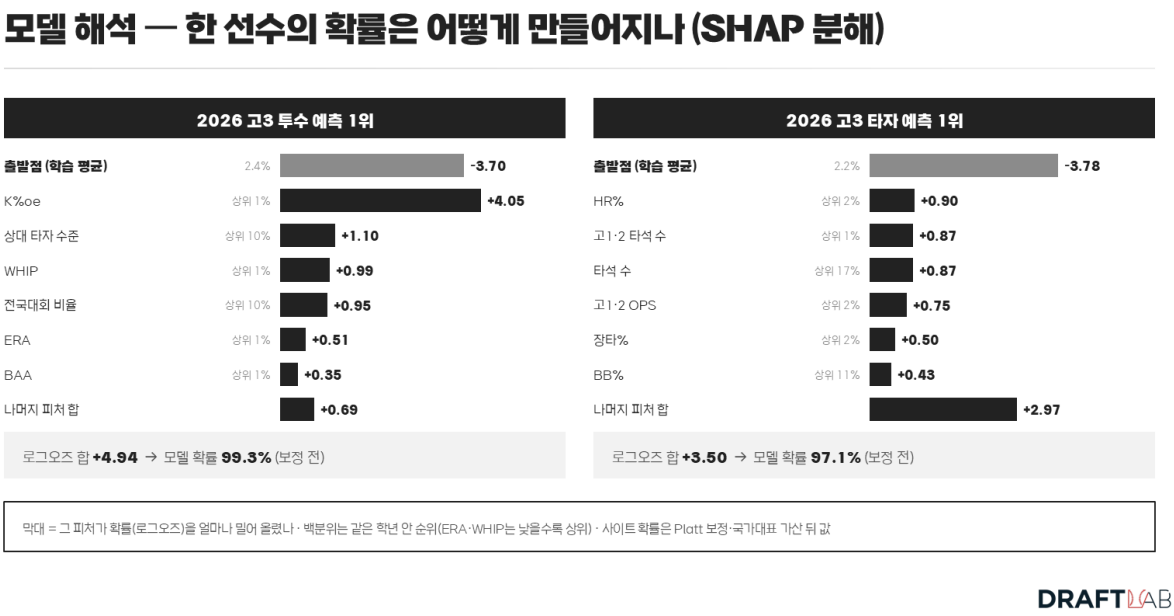


그림 8. 한 선수의 확률 분해 — 2026 고 3 투수·타자 예측 1 위 (보정 전 모델 확률)

한 선수 단위로 보면, 학습 평균(약 2%)에서 출발해 피처마다 로그오즈를 더하고 빼서 최종 확률이 만들어진다. 투수 1 위는 K%oe 하나가 +4.05 를 더해 확률 대부분을 설명했고, 타자 1 위는 HR%·고 1·2 타석 수·타석 수·고 1·2 OPS 가 고르게 기여했다. 이 분해를 예측 화면에 함께 보여 주면 '왜 이 확률인가'에 답할 수 있다.

5.6 확률 보정

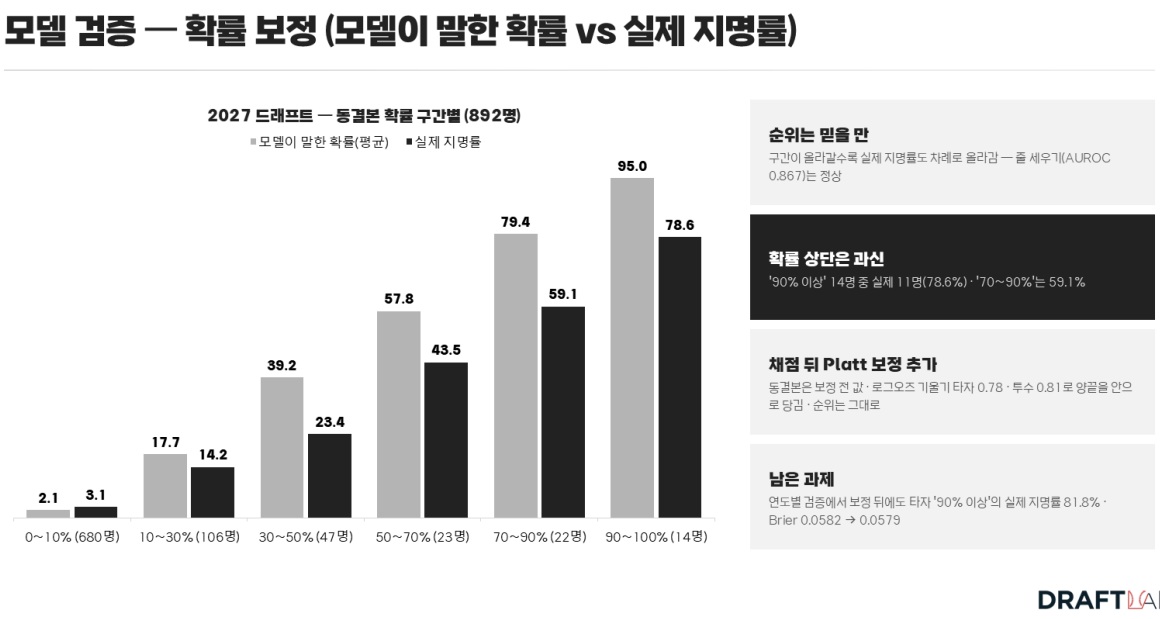


그림 9. 확률 구간별 모델이 말한 확률과 실제 지명률 (2027 동결본)

동결본은 순위는 정확했지만 확률 상단이 과신돼 있었다. '90% 이상'이라고 한 14 명 중 실제 지명은 11 명(78.6%), '70~90%'는 59.1%였다. 그래서 드래프트 뒤(09-21) OOF 예측으로 Platt 보정을 추가했다. 로그오즈 기울기는 타자 0.775, 투수 0.813 로 1 보다 작아 양끝을 안쪽으로 당긴다. 단조 변환이라 순위와 AUROC 는 그대로다. 다만 연도별 검증에서 보정의 Brier 개선은 0.0582 → 0.0579 로 작아, 확률 상단의 과신은 남은 과제다.

5.7 오류 분석

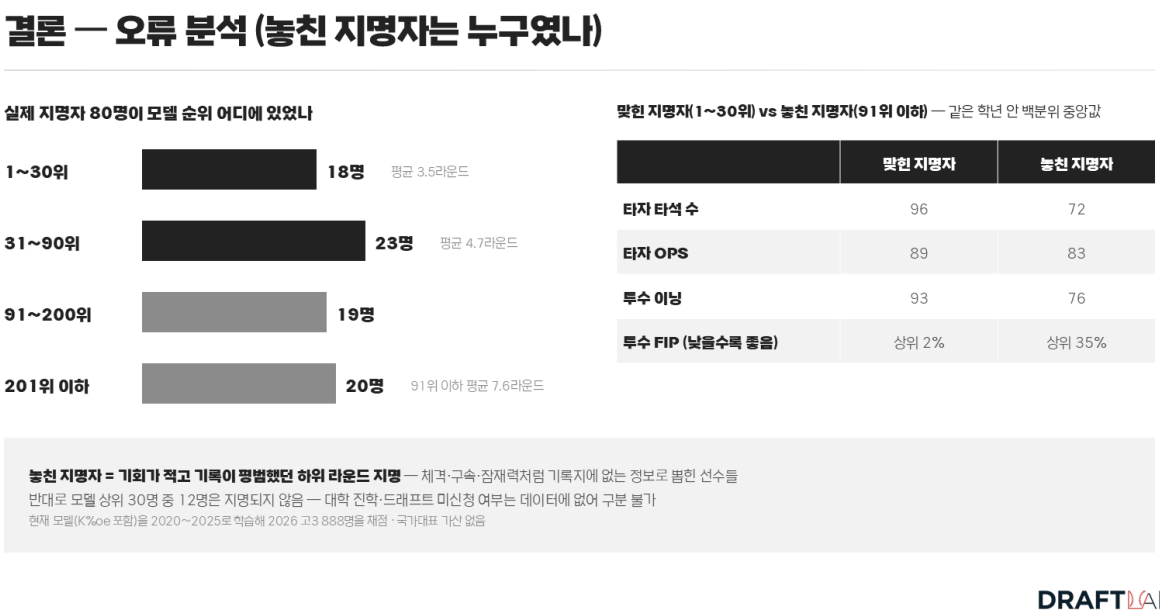


그림 10. 오류 분석 — 실제 지명자의 모델 순위와 기록 수준

2027 실전에서 지명자 80 명 중 18 명은 모델 1~30 위, 23 명은 31~90 위였고, 39 명은 91 위 아래에 있었다. 모델이 놓친 지명자는 평균 7.6 라운드로, 맞힌 지명자(평균 3.5 라운드)보다 훨씬 늦게 뽑혔다. 놓친 지명자의 같은 학년 안 백분위 중앙값은 타자 타석 수 72(맞힌 지명자 96), 투수 이닝 76(93)로, 기회가 적고 기록이 평범했다. 이들은 체격·구속·잠재력처럼 기록지에 없는 정보로 뽑혔을 가능성이 크다. 반대로 모델 상위 30 명 중 12 명은 지명되지 않았는데, 대학 진학이나 드래프트 미신청 여부가 데이터에 없어 모델 오류와 구분할 수 없다.

5.8 국가대표 가산치 개선

동결본은 U-18 국가대표의 확률을 로그오즈 +1 만큼 올렸다. 과거 대표 명단이 없어 사람이 정한 값이었다. 이후 명단이 채워져 2022~2026 고 3 대표의 실제 지명률을 보니 해마다 76~100%였는데, 모델은 이들을 평균 60% 안팎으로 봤다. 그래서 네 방식을 같은 데이터로 비교했다.

표 15. 국가대표 반영 방식 비교 (2027 실전은 889 명 · 지명 81 명)

방식	검증 AUROC	2027 AUROC	상위 10	상위 30	상위 50	대표 확률→실제
기존 (국가대표 정보 없음)	0.893	0.883	8	17	30	58.6% → 100%
규칙 +1 (지금 사이트)	0.893	0.889	9	19	30	72.1% → 100%
B 가산치를 데이터로	0.896	0.893	10	21	32	88.3% → 100%
A 피처로 학습	0.896	0.893	8	20	31	73.1% → 100%

피처로 학습하는 방식(A)은 대표가 학습 전체에서 70 명 남짓이라 효과를 덜 잡아 대표를 평균 73%로 봤다. 사후 가산의 크기를 데이터로 맞추는 방식(B)은 AUROC 가 같으면서 2027 상위 10 명이 모두 실제 지명자였다. 그래서 B 를 채택했다. 학습 코호트(2022~2025) 대표의 보정 확률과 실제 지명으로 가산치를 최대우도로 맞추며, 예측 학년은 쓰지 않는다. 사이트에 반영한 값은 **타자 +2.40, 투수 +2.70** 이다(2026-10-27). 2027 은 가산치를 맞출 때 쓰지 않았지만 방식을 고를 때는 봤으므로, 깨끗한 검증은 2028 드래프트다.

5.9 성과

- 주자 상황이 포함되고 공식 기록과 3 중 대조를 통과한 **7 시즌 타석 단위 데이터셋**
- 고교야구 득점 환경에 맞춘 **리그 맞춤 세이버매트릭스** 엔진
- 실제 드래프트로 검증한 **지명 예측 모델** (AUROC 0.867, 상위 10 명 중 8 명)
- 다른 모델·단순 기준선과의 비교, 피처 제거 실험, SHAP 해석으로 **모델 선택과 피처 설계의 근거**를 수치로 확인
- 데이터 보호·권한·관리 도구를 갖추고 실제 운영 중인 **웹 서비스 rookiezpark.com**

5.10 한계

- 기록 밖 정보(신장·체중·구속)가 없다. 모델이 놓친 지명자는 대부분 하위 라운드 지명으로, 기록만으로는 판단하기 어려운 영역이다.
- 확률 상단이 과신된다. Platt 보정을 더했지만 연도별 검증에서도 개선 폭이 작았다.
- 드래프트 전에 동결해 채점한 것은 2027 한 번뿐이다. 시간순 검증 다섯 해로 보완했지만, 로지스틱 회귀와 LightGBM 의 우열처럼 작은 차이는 가리지 못한다.

- U-18 국가대표 가산은 여전히 학습 밖에서 얹는 사후 가산이다. 크기는 2022~2025 결과로 맞췄지만 깨끗한 검증은 2028 드래프트다.
- 파크팩터는 아직 실험 단계라 관리자·파트너에게만 보여주고, 중계 영상 분석(구속·구종 추출)은 실험 단계라 사이트 공개를 보류했다.
- 수비 기록이 빠져 있어 승리기여는 공격 쪽(oWAR)만 계산한다.
- 사이트는 갱신 시점의 정적 스냅샷이라, 투구수 관리 같은 날짜 의존 화면은 기준일이 고정된다.

5.11 향후 과제

- 신장·체중과 영상 분석 구속을 연도별 보유율 편향 없이 모아 기록 외 피처로 더한다.
- 갱신할 때마다 예측을 기록해 두어, 시즌 중 선수별 지명 확률이 어떻게 바뀌었는지 보인다.
- 국가대표 표본이 쌓이면 가산 대신 피처로 학습하고 사후 가산을 걷어낸다.
- 학교 코치진용 경기 기록기를 사이트와 연결해 현장 기록을 협회 기록과 대조한다.
- 2028 드래프트도 같은 절차(사전 동결 → 채점)로 두 번째 실전 검증을 한다.

6. 참고문헌

[1] DBpia, '고교야구 지명 예측' 검색 결과. https://www.dbpia.co.kr

[2] FanGraphs Blog, MLB Outlaws Amateur TrackMan Data Exclusivity. https://blogs.fangraphs.com/mlb-outlaws-amateur-trackman-data-exclusivity/

[3] 위키백과, 2023~2027 년 KBO 리그 신인 드래프트. https://ko.wikipedia.org

[4] 대한야구소프트볼협회(KBSA). https://www.korea-baseball.com

[5] TVING, 한국 vs 호주 다시보기. https://www.tving.com/contents/L00000298230

[6] Rookiezpark. https://rookiezpark.com

7. 개발 일정과 역할 분담

7.1 1 학기 — 모델 개발 (15 주)

표 16. 1 학기 일정

작업	기간(주차)
데이터 수집 (기록지 작성)	1 ~ 11
UI 디자인	4 ~ 7
데이터 검수	4 ~ 12
데이터 전처리 및 스탯 정리	5 ~ 12
탐색적 데이터 분석(EDA)	6 ~ 13
모델링 및 분석	12 ~ 14
해석 및 시각화	10 ~ 14
리팩토링	13 ~ 15

7.2 2 학기 — 서비스 확장 (2026.07 ~ 10)

표 17. 2 학기 주요 이정표 (커밋 825 개: pipeline 334 · web 491)

월	커밋	주요 이정표
2026.07	288	웹 사이트 공개, 드래프트 예측 탭(07-21), 영상 분석 실험(07-29), 로그인 도입(07-31)
2026.08	200	4 개 학년 예측 학습(08-07), 파크팩터 7 시즌(08-24), Colab 원격 갱신(08-26), 주자 추적 불일치 0(08-30)
2026.09	217	드래프트 입력기(09-17), 예측 자동 동결(09-18), 2027 드래프트 채점(09-21), U-18 국가대표 기록(09-25)
2026.10	120	RE24 마르코프 전환(10-02), 갱신 30 분 → 15 분(10-06), 6 개 언어 지원(10-17), 학교용 경기 기록기(10-19), 국가대표 가산치·예측 등급(10-27)

7.3 역할 분담

표 18. 역할 분담

이름	역할
류산성	주자 상황 생성을 위한 데이터 입력, 데이터 전처리, AI 모델링, Tableau 대시보드
마태림	주자 상황 생성을 위한 데이터 입력, 데이터 전처리, 세이버매트릭스 지표 분포 분석, 지명 가능성과 지표 관계 체계 제작
표룡희	BeautifulSoup 데이터 크롤링, 주자 상황 생성을 위한 데이터 입력, 세이버매트릭스 스탯 생성 및 재구성, AI 모델링, 웹 서비스·파이프라인 개발 및 운영
홍록기	주자 상황 생성을 위한 데이터 입력, UI 디자인, 데이터 검수, 리팩토링